

XÁC SUẤT THỐNG KÊ

Nguyen Tran Anh Quan^{*a}

*Corresponding/Presenting Author Email: nguyentrananhquan121005@gmail.com

Machine Learning & IoT Lab (ML IoT)
Ho Chi Minh City University of Technology (HCMUT)

1. Khái niệm cơ bản về xác suất
2. Biến ngẫu nhiên và phân phối xác suất
3. Đặc trưng thống kê
4. Thực hành với Python

Mục tiêu buổi học

- ▶ Ôn tập xác suất
- ▶ Hiểu vai trò của xác suất trong Machine Learning.
- ▶ Mô tả dữ liệu bằng phân phối và thống kê.

Một phép thử ngẫu nhiên (hay thí nghiệm ngẫu nhiên) là một quy trình dẫn đến một kết quả xác định được nhưng không hoàn toàn dự đoán được. Chúng ta quan tâm đến khả năng xảy ra của các tổ hợp kết quả.

Một phép thử ngẫu nhiên (hay thí nghiệm ngẫu nhiên) là một quy trình dẫn đến một kết quả xác định được nhưng không hoàn toàn dự đoán được. Chúng ta quan tâm đến khả năng xảy ra của các tổ hợp kết quả.

Ví dụ

- ▶ Phép thử ngẫu nhiên: tung xúc xắc.

Định nghĩa (không gian xác suất)

Không gian xác suất là một bộ ba $(\Omega, \mathcal{F}, \mathbb{P})$ gồm không gian mẫu Ω , không gian biến cố $\mathcal{F}$ và hàm xác suất $\mathbb{P}$.

Không gian xác suất mô hình hóa phép thử ngẫu nhiên

- ▶ Ω : các kết quả có thể.
- ▶ $\mathcal{F}$: các tổ hợp kết quả có thể.
- ▶ $\mathbb{P}$: khả năng xảy ra của các tổ hợp.

Định nghĩa (không gian mẫu và kết quả)

Không gian mẫu là một tập hợp. Các phần tử của không gian mẫu được gọi là các kết quả.

Ví dụ

- ▶ $\Omega = \{\text{mặt 1, mặt 2, mặt 3, mặt 4, mặt 5, mặt 6}\}.$
- ▶ $\Omega = \{\text{mặt 1, mặt 2, mặt 3, mặt 4, mặt 5, mặt 6,}$
 $\text{mặt 1 dưới tủ, mặt 2 dưới tủ, mặt 3 dưới tủ,}$
 $\text{mặt 4 dưới tủ, mặt 5 dưới tủ, mặt 6 dưới tủ}\}.$

Lưu ý Bất kì tập hợp nào cũng có thể là một không gian mẫu.

Định nghĩa (biến cố)

Một biến cố là một tập hợp các kết quả. Nói cách khác, một biến cố là một tập con của không gian mẫu.

Ví dụ

$\Omega = \{\text{mặt 1, mặt 2, mặt 3, mặt 4,}$
mặt 5, mặt 6, mặt 1 dưới tủ, mặt 2 dưới tủ,
mặt 3 dưới tủ, mặt 4 dưới tủ, mặt 5 dưới tủ, mặt 6 dưới tủ}\}.

Các ví dụ cụ thể

- ▶ “thấy mặt 3” = {mặt 3}.
- ▶ “thấy mặt chẵn” = {mặt 2, mặt 4, mặt 6}.
- ▶ “ra mặt chẵn” = {mặt 2, mặt 4, mặt 5, mặt 6, mặt 2 dưới tủ, mặt 4 dưới tủ, mặt 6 dưới tủ}.

Định nghĩa (biến cố tạo thành từ các biến cố khác)

- ▶ Biến cố đối của biến cố A , ký hiệu A^c , là phần bù của A trong Ω .
- ▶ Biến cố hợp của hai biến cố A và B , ký hiệu $A \cup B$, là hợp của A và B .
- ▶ Biến cố giao của hai biến cố A và B , ký hiệu $A \cap B$, là giao của A và B .

Ví dụ

- ▶ “ra mặt chẵn”^c = “ra mặt lẻ”
- ▶ “ra mặt chẵn” $\cup$ “ra mặt lẻ” = Ω
- ▶ “ra mặt chẵn” $\cap$ “ra mặt lẻ” = $\emptyset$

Định nghĩa (hàm xác suất)

Một hàm xác suất của không gian biến cố $\mathcal{F}$ là một độ đo xác suất trên $\mathcal{F}$.

Gợi nhớ

Một độ đo xác suất $\mathbb{P}$ trên $\mathcal{F}$ là một ánh xạ $\mathcal{F} \rightarrow \mathbb{R}$ thỏa:

- ▶ Với mọi $E \in \mathcal{F}$, $\mathbb{P}(E) \geq 0$.
- ▶ $\mathbb{P}(\Omega) = 1$.
- ▶ Với mọi dãy $E_1, E_2, \dots \in \mathcal{F}$ đôi một không giao nhau,

$$\mathbb{P}\left(\bigcup_{i \geq 1} E_i\right) = \sum_{i \geq 1} \mathbb{P}(E_i).$$

Trực quan

Độ đo xác suất cho biết kích thước của biến cố, phản ánh khả năng xảy ra của tổ hợp kết quả.

- ▶ Không gian mẫu: tập hợp tất cả các kết quả của một phép thử ngẫu nhiên, thường được ký hiệu là Ω .
- ▶ Biến cố: tập hợp các kết quả (tập con của Ω), có thể gán xác suất.
Không gian biến cố: tập hợp tất cả biến cố, thường được ký hiệu là $\mathcal{F}$.
- ▶ Hàm xác suất: ánh xạ $\mathcal{F} \rightarrow \mathbb{R}$ thỏa các tiên đề xác suất, thường được ký hiệu là $\mathbb{P}$.
- ▶ Không gian xác suất: $(\Omega, \mathcal{F}, \mathbb{P})$.

Phân biệt

Xác suất: Khả năng xảy ra của một tổ hợp kết quả.

Xác suất có điều kiện: Khả năng xảy ra của một tổ hợp kết quả A , khi biết một tổ hợp kết quả B đã xảy ra.

Định nghĩa (xác suất có điều kiện)

Cho không gian xác suất $(\Omega, \mathcal{F}, \mathbb{P})$ và hai biến cố $A, B \in \mathcal{F}$ với $\mathbb{P}(B) > 0$.

Xác suất có điều kiện của A biết B , ký hiệu $\mathbb{P}(A|B)$, được định nghĩa là


$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

Lưu ý

$\mathbb{P}(A|B)$ không được định nghĩa khi $\mathbb{P}(B) = 0$.

Đầu ra của mô hình AI là phân phối xác suất

Các mô hình sinh thường dự đoán dưới dạng xác suất, giúp thể hiện độ tin cậy và ra quyết định trong điều kiện không chắc chắn.



Mô hình ngôn ngữ sinh phân phối xác suất

Định nghĩa (hai biến cố độc lập)

Cho không gian xác suất $(\Omega, \mathcal{F}, \mathbb{P})$ và hai biến cố $A, B \in \mathcal{F}$. Hai biến cố A và B được gọi là độc lập nếu

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \mathbb{P}(B).$$

Hệ quả

Khi $\mathbb{P}(B) > 0$, ta có $\mathbb{P}(A \cap B) = \mathbb{P}(A|B) \mathbb{P}(B)$, hay nói cách khác,

$$\mathbb{P}(A|B) = \mathbb{P}(A).$$

Trực quan

Nếu A và B độc lập thì việc biết B xảy ra (hay không) không thay đổi khả năng xảy ra của A .

Lưu ý

Độc lập khác với xung khắc.

Định lý (Định lý Bayes)

Cho không gian xác suất $(\Omega, \mathcal{F}, \mathbb{P})$ và hai biến cố A, B thỏa $\mathbb{P}(A) > 0$ và $\mathbb{P}(B) > 0$. Khi đó,

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(B|A) \mathbb{P}(A)}{\mathbb{P}(B)}.$$

Giải thích các thành phần

- ▶ $\mathbb{P}(A)$: xác suất tiên nghiệm (prior)
- ▶ $\mathbb{P}(A|B)$: xác suất hậu nghiệm (posterior)
- ▶ $\mathbb{P}(B|A)$: hợp lý (likelihood)

Các công thức quan trọng

- ▶ Hai biến cố độc lập:

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \mathbb{P}(B)$$

- ▶ Xác suất có điều kiện: với $\mathbb{P}(B) > 0$

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$$

- ▶ Công thức xác suất toàn phần: với dãy biến cố $B_1, B_2, \dots$ đôi một xung khắc sao cho $\bigcup_{i \geq 1} B_i = \Omega$


$$\mathbb{P}(A) = \sum_{i \geq 1} \mathbb{P}(A|B_i) \mathbb{P}(B_i)$$

- ▶ Định lý Bayes: với $\mathbb{P}(A) > 0$ và $\mathbb{P}(B) > 0$,

$$\mathbb{P}(B|A) = \frac{\mathbb{P}(A|B) \mathbb{P}(B)}{\mathbb{P}(A)}$$

Tình huống

Bạn có biết rằng từ “offer” xuất hiện trong 80% các email rác, nhưng chỉ xuất hiện trong 10% email hợp lệ? Giả sử tỉ lệ thư rác trong tổng số email nhận được là 30%. Hôm nay, bạn nhận được một email mới có chứa từ “offer”. Vậy xác suất nó là thư rác là bao nhiêu?



Định nghĩa (biến ngẫu nhiên)

Cho không gian xác suất $(\Omega, \mathcal{F}, \mathbb{P})$. Một biến ngẫu nhiên (bnn) là một hàm giá trị thực đo được trên $(\Omega, \mathcal{F})$.

Gợi nhớ

Một hàm X giá trị thực đo được trên $(\Omega, \mathcal{F})$ là một ánh xạ

$$X : \Omega \rightarrow \mathbb{R}$$

thỏa mãn

$$\{\omega \in \Omega \mid X(\omega) \leq r\} \in \mathcal{F} \quad \text{với mọi } r \in \mathbb{R}.$$

Lưu ý

Biến ngẫu nhiên là một ánh xạ (không phải biến) xác định (không ngẫu nhiên).

Xét phép thử tung đồng xu cân đối hai lần.

- ▶ Không gian mẫu: $\Omega = \{SS, SN, NS, NN\}$
- ▶ Không gian biến cố: $\mathcal{F} = \mathcal{P}(\Omega)$
- ▶ Hàm xác suất: $\mathbb{P}(E) = |E|/4$ với mọi $E \in \mathcal{F}$

Một số biến ngẫu nhiên

- ▶ Gọi X_1 là bnn chỉ tổng số lần mặt ngửa xuất hiện.

$$X_1(SS) = 0, \quad X_1(SN) = X_1(NS) = 1, \quad X_1(NN) = 2$$

- ▶ Gọi X_2 là bnn luôn nhận giá trị 3698.

$$X_2(SS) = X_2(SN) = X_2(NS) = X_2(NN) = 3698$$

- ▶ Gọi X_3 là bnn thỏa

$$X_3(SS) = 3, \quad X_3(SN) = 6, \quad X_3(NS) = 9, \quad X_3(NN) = 8$$

Định nghĩa (phân loại bnn)

Cho không gian xác suất $(\Omega, \mathcal{F}, \mathbb{P})$. Xét bnn X có hàm phân phối tích lũy F_X và $X(\Omega) = \{X(\omega) \mid \omega \in \Omega\}$.

- ▶ X được gọi là bnn rời rạc nếu $X(\Omega)$ đếm được (hữu hạn hoặc vô hạn đếm được).
- ▶ X được gọi là bnn liên tục nếu tập $X(\Omega)$ vô hạn không đếm được và F_X liên tục trên $\mathbb{R}$.
- ▶ X được gọi là bnn hỗn hợp trong các trường hợp khác.

Lưu ý

Phân loại bnn giúp chọn cách mô tả phân phối phù hợp: hàm khối xác suất (PMF) cho rời rạc, hàm mật độ xác suất (PDF) cho liên tục.

Định nghĩa

Một phân phối xác suất của bnn X là một mô tả về xác suất X nhận từng giá trị cụ thể hoặc trong một khoảng cụ thể trên $\mathbb{R}$.

Các hàm xác định một phân phối xác suất

- ▶ Hàm phân phối tích lũy (CDF)
- ▶ Hàm khối xác suất (PMF) – dành cho bnn rời rạc
- ▶ Hàm mật độ xác suất (PDF) – dành cho bnn liên tục

Định nghĩa (hàm phân phối tích lũy)

Cho không gian xác suất $(\Omega, \mathcal{F}, \mathbb{P})$. Hàm phân phối tích lũy của một bnn X , ký hiệu F_X , được định nghĩa là

$$F_X(x) := \mathbb{P}(X \leq x), \quad \forall x \in \mathbb{R}.$$

Tính chất

- ▶ Không giảm: $x_1 < x_2 \Rightarrow F_X(x_1) \leq F_X(x_2)$
- ▶ Liên tục phải: $\lim_{x \rightarrow x_0^+} F_X(x) = F_X(x_0)$
- ▶ Bị chặn hai phía:

$$\lim_{x \rightarrow -\infty} F_X(x) = 0, \quad \lim_{x \rightarrow +\infty} F_X(x) = 1$$

Lưu ý

Một hàm thỏa các tính chất trên là hàm phân phối tích lũy của một bnn nào đó.

Bài toán

Tung đồng xu không cân đối với xác suất 75% ra mặt ngửa. Xét bnn X nhận giá trị $+1$ nếu đồng xu ra mặt ngửa và -1 nếu đồng xu ra mặt sấp. Hàm phân phối tích lũy của X là gì?

Bài toán

Tung đồng xu không cân đối với xác suất 75% ra mặt ngửa. Xét bnn X nhận giá trị +1 nếu đồng xu ra mặt ngửa và -1 nếu đồng xu ra mặt sấp. Hàm phân phối tích lũy của X là gì?

Trả lời

$$\Omega = \{S, N\}, \quad \mathcal{F} = \mathcal{P}(\Omega), \quad \mathbb{P}(\{S\}) = 1 - \mathbb{P}(\{N\}) = 0.25$$

$$X(\omega) = \begin{cases} +1, & \omega = S \\ -1, & \omega = N \end{cases}$$

$$F_X(x) = \begin{cases} 0, & x < -1 \\ 0.25, & -1 \leq x < 1 \\ 1, & 1 \leq x \end{cases}$$

Định nghĩa (hàm khối xác suất)

Cho không gian xác suất $(\Omega, \mathcal{F}, \mathbb{P})$ và bnn X . Hàm khối xác suất của X , ký hiệu p_X , được định nghĩa là

$$p_X(x) := \mathbb{P}(X = x), \quad \forall x \in \mathbb{R}.$$

Bài toán

Tung một đồng xu cân đối hai lần. Gọi X là bnn chỉ số lần ra mặt ngửa. Hàm khối xác suất của X là gì?

Tóm Tắt

$$\Omega = \{SS, SN, NS, NN\}, \quad \mathcal{F} = \mathcal{P}(\Omega), \quad \mathbb{P}(E) = |E|/4$$

Lưu ý quan trọng

Với bnn liên tục, hàm khối xác suất bằng 0 ở mọi điểm.

Trực quan

Do $X(\Omega)$ vô hạn không đếm được, có quá nhiều giá trị của X để có thể gán xác suất dương.

Định nghĩa (hàm mật độ xác suất)

Cho không gian xác suất $(\Omega, \mathcal{F}, \mathbb{P})$ và bnn liên tục X . Hàm mật độ xác suất của X , ký hiệu f_X , được định nghĩa là

$$f_X(x) := \frac{d}{dx}F_X(x)$$

với mọi $x \in \mathbb{R}$ mà F_X khả vi.

Trực quan

Xác suất trên một khoảng nhỏ:

$$\frac{d}{dx}F_X(x) = \lim_{h \rightarrow 0^+} \frac{F_X(x) - F_X(x-h)}{h} = \lim_{h \rightarrow 0^+} \frac{\mathbb{P}(x-h < X \leq x)}{h}.$$

Các hàm quan trọng

▶ Biến ngẫu nhiên: ánh xạ $\Omega \rightarrow \mathbb{R}$

▶ Hàm phân phối tích lũy: Với $x \in \mathbb{R}$

$$F_X(x) = \mathbb{P}(X \leq x)$$

▶ Hàm khối xác suất: Với $x \in \mathbb{R}$

$$p_X(x) = \mathbb{P}(X = x)$$

▶ Hàm mật độ xác suất (cho bnn liên tục): Với $x \in \mathbb{R}$ mà F_X khả vi

$$f_X(x) = F'_X(x)$$

Định nghĩa

Kỳ vọng (hay giá trị trung bình) của bnn X , ký hiệu $\mathbb{E}[X]$ hoặc μ_X , là giá trị trung bình có trọng số của X , với trọng số là xác suất tương ứng.

Công thức

- ▶ bnn rời rạc:

$$\mathbb{E}[X] = \sum_{x \in X(\Omega)} x \cdot p_X(x)$$

- ▶ bnn liên tục:

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x \cdot f_X(x) dx$$

Thực quan

Kỳ vọng là trung tâm phân phối của bnn, nơi tập trung nhiều khối lượng xác suất nhất.

Định nghĩa

- ▶ Phương sai: $\text{Var}(X) = \mathbb{E}[(X - \mu_X)^2]$.
- ▶ Độ lệch chuẩn: $\sigma_X = \sqrt{\text{Var}(X)}$.

Công thức tính (rời rạc)

$$\text{Var}(X) = \sum_{x \in X(\Omega)} (x - \mu_X)^2 p_X(x)$$

Thực quan

- ▶ Phương sai đo mức độ phân tán quanh giá trị trung bình.
- ▶ Độ lệch chuẩn cùng đơn vị với dữ liệu nên dễ giải thích hơn.

Đo xu hướng trung tâm

- ▶ Mean (trung bình): $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$
 - ▶ Nhạy cảm với outlier.
- ▶ Median (trung vị): giá trị ở vị trí chính giữa sau khi sắp xếp.
 - ▶ Bền vững với outlier.
- ▶ Mode (yếu vị): giá trị xuất hiện nhiều nhất.
 - ▶ Hữu ích cho dữ liệu phân loại (categorical).

Bảng dữ liệu điểm số của 10 sinh viên

STT	1	2	3	4	5	6	7	8	9	10
Điểm	5	6	7	5	6	8	7	6	100	NA

(Giá trị khuyết NA, outlier là 100)

Dữ liệu gốc (bỏ qua NA)

Mean ≈ 16.67 , Median = 6

Nhận xét

Mean bị kéo lệch mạnh bởi outlier 100, trong khi median vẫn đại diện tốt hơn cho nhóm điểm chính.

Điền NA bằng Mean

Giá trị mới = 16.67

Mean mới = 16.67

Median mới = 6.5

Mean bị kéo lệch bởi outlier.

Điền NA bằng Median

Giá trị mới = 6

Mean mới = 15.6

Median mới = 6

Median ít nhạy với outlier.

Kết luận

Median bền vững hơn, phù hợp để điền khuyết khi dữ liệu có nhiều/outlier.

Định nghĩa

- ▶ Quantile: chia dữ liệu theo tỷ lệ; $Q1$ (25%), $Q2$ (50%), $Q3$ (75%).
- ▶ Percentile: quantile theo thang 0–100.
- ▶ IQR: khoảng giữa $Q3$ và $Q1$.

$$IQR = Q3 - Q1$$

Ứng dụng

- ▶ Phát hiện outlier bằng ngưỡng $Q1 - 1.5IQR$ và $Q3 + 1.5IQR$.
- ▶ Mô tả mức độ phân tán không bị ảnh hưởng bởi outlier.
- ▶ Xây dựng boxplot để trực quan hóa.

Dữ liệu: điểm thi của 15 sinh viên

42, 45, 48, 50, 52, 55, 58, 60, 62, 65, 68, 70, 75, 80, 95

Hiệp phương sai (Covariance)

Đo mức độ hai biến X, Y biến thiên cùng chiều hay ngược chiều:

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mu_X)(Y - \mu_Y)]$$

- ▶ $\text{Cov}(X, Y) > 0$: cùng chiều.
- ▶ $\text{Cov}(X, Y) < 0$: ngược chiều.

Hệ số tương quan (Correlation)

Chuẩn hóa covariance về khoảng $[-1, 1]$:

$$\rho_{X,Y} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

- ▶ $\rho = 1$: tương quan dương hoàn hảo.
- ▶ $\rho = -1$: tương quan âm hoàn hảo.
- ▶ $\rho = 0$: không tương quan tuyến tính.

Dữ liệu: số giờ tự học và điểm thi của 5 sinh viên

Sinh viên	Giờ tự học X	Điểm thi Y
1	2	50
2	4	60
3	6	70
4	8	80
5	10	90

Trung bình

$$\bar{X} = 6, \quad \bar{Y} = 70$$

Nhận xét nhanh

Khi X tăng đều từ 2 đến 10, Y cũng tăng đều từ 50 đến 90.

Mục tiêu

Sử dụng thư viện numpy và scipy để tính các đặc trưng thống kê đã học:

- ▶ Mean, median, mode, quantile, IQR.
- ▶ Covariance và correlation.
- ▶ Vẽ biểu đồ phân phối (histogram, boxplot, scatter plot).

Dữ liệu mẫu

Chúng ta sẽ dùng bộ dữ liệu đơn giản: $\text{var1} = [1, 3, 4, 4]$ và $\text{var2} = [1, 2, 3, 2]$.

Code Python với NumPy

```
import numpy as np

var1 = np.array([1, 3, 4, 4])
var2 = np.array([1, 2, 3, 2])

cov = np.cov(var1, var2)
corr = np.corrcoef(var1, var2)
print(cov)
print(corr)
```

Kết quả chính

- ▶ Covariance matrix: $\begin{bmatrix} 2.0 & 1.0 \\ 1.0 & 0.667 \end{bmatrix}$.
- ▶ Correlation matrix: $\begin{bmatrix} 1.0 & 0.866 \\ 0.866 & 1.0 \end{bmatrix}$.
- ▶ $\rho \approx 0.866$: tương quan dương khá mạnh.

Code Python với NumPy

```
import numpy as np

data = np.array([42, 45, 48, 50, 52, 55, 58,
                 60, 62, 65, 68, 70, 75, 80, 95])

q1, q2, q3 = np.percentile(data, [25, 50, 75])
iqr = q3 - q1

print("Mean:", np.mean(data))
print("Median:", np.median(data))
print("Q1, Q2, Q3:", q1, q2, q3)
print("IQR:", iqr)
```

Kết quả chính

Mean $\approx$ 60.87, Median = 60, Q1 = 50, Q2 = 60, Q3 = 70, IQR = 20.

Thank You

Acknowledgements

The authors gratefully acknowledge [Funding agency / Collaborators / Lab / Advisor names] for their support and guidance.