

Giới thiệu Machine Learning: Quy trình dự án, EDA, Tiền xử lý & Đánh giá mô hình

Module 2 — Machine Learning · Buổi 5 / 22

Khóa học hè 2026 — Python & Machine Learning

Tài liệu & hỗ trợ học viên: mlandiotlab@gmail.com

Machine Learning & IoT Lab (ML IoT)
Ho Chi Minh City University of Technology (HCMUT)

Phần 1 — Giới thiệu Machine Learning

45'

- ▶ Machine Learning và lập trình truyền thống
- ▶ Phân loại bài toán: Supervised, Unsupervised, Reinforcement
- ▶ Pipeline chuẩn của một dự án ML
- ▶ Thư viện Scikit-learn

Phần 2 — Khám phá dữ liệu (EDA)

45'

- ▶ Kiểm tra shape, dtype, missing, outlier
- ▶ Phân tích univariate, bivariate, multivariate
- ▶ Trực quan hóa dữ liệu

Phần 3 — Tiền xử lý dữ liệu

45'

- ▶ Xử lý missing value & outlier
- ▶ Encoding biến phân loại
- ▶ Chuẩn hóa dữ liệu (scaling)
- ▶ Chia tập train / validation / test

Phần 4 — Đánh giá mô hình

45'

- ▶ Overfitting, underfitting, bias–variance
- ▶ Metric cho hồi quy & phân loại
- ▶ Cross-Validation
- ▶ **Thực hành: EDA & tiền xử lý trên Titanic**

Sau buổi học, học viên có thể:

1. Mô tả pipeline chuẩn của một dự án Machine Learning.
2. Thực hiện EDA đầy đủ trên một dataset thực tế (Titanic).
3. Áp dụng các kỹ thuật tiền xử lý phù hợp với từng loại dữ liệu.
4. Phân biệt và lựa chọn metric đánh giá phù hợp với từng bài toán.
5. Hoàn thành notebook EDA & Preprocessing trên Titanic, kèm nhận xét về dữ liệu.

Dataset Titanic được dùng làm case study xuyên suốt cả buổi học.

Nếu bạn ở trên tàu Titanic, khả năng sống sót của bạn là bao nhiêu?

Cuối buổi học, chúng ta sẽ chuẩn bị xong toàn bộ dữ liệu để một mô hình có thể trả lời câu hỏi này.

1

Giới thiệu Machine Learning

Định nghĩa · Phân loại bài toán · Pipeline · Scikit-learn — 45 phút

Can a machine *discover* the rules, instead of being told them?

Liệu máy có thể tự tìm ra quy luật từ dữ liệu, thay vì được con người lập trình sẵn?

➤ HOẠT ĐỘNG

Vòng 1 — dễ

- ▶ “FREE money now”
- ▶ “You WIN a prize”
- ▶ “\$\$\$ click here”

Một vài quy tắc theo từ khóa là đủ.

Vòng 2 — khó


- ▶ “Meeting tomorrow at 9am”
- ▶ “FREE lunch for the team”

Từ khóa “FREE” xuất hiện ở email hợp lệ — quy tắc bắt đầu sai.

Khi số ngoại lệ tăng, danh sách quy tắc phình to nhưng vẫn không bao phủ hết. Cần một cách khác: để máy *tự học* ranh giới spam / không spam từ dữ liệu đã gán nhãn.

Định nghĩa

Machine Learning là lĩnh vực xây dựng các mô hình *học quy luật trực tiếp từ dữ liệu*, thay vì được lập trình tường minh bằng các quy tắc do con người đặt ra.



Lập trình truyền thống



Machine Learning

Trong lập trình truyền thống, quy tắc là đầu vào; trong Machine Learning, quy tắc là đầu ra của quá trình học.



Machine Learning là quá trình biến dữ liệu thành quyết định

Nhiều hệ thống quen thuộc vận hành theo chuỗi trên: hệ thống quảng cáo của Google, hệ thống gợi ý của Netflix và Shopee đều học từ dữ liệu hành vi trong quá khứ, đưa ra dự đoán, rồi chuyển dự đoán thành quyết định hiển thị nội dung phù hợp với từng người dùng.

Google Search


Dữ liệu truy vấn & lượt click → học quy luật mức độ liên quan
→ xếp hạng kết quả tìm kiếm.

ChatGPT

Khối lượng lớn văn bản → học quy luật ngôn ngữ
(pretraining) → dự đoán từ tiếp theo.




Các hệ thống rất khác nhau về quy mô nhưng chia sẻ cùng một khuôn mẫu: học từ dữ liệu để dự đoán.



Quan hệ bao hàm

- ▶ **AI:** mọi kỹ thuật giúp máy thực hiện tác vụ đòi hỏi trí tuệ.
- ▶ **ML:** nhánh của AI, học quy luật từ dữ liệu.
- ▶ **DL:** nhánh của ML, dùng mạng nơ-ron nhiều lớp.

Deep Learning được trình bày chi tiết ở Module 3.



Dạng của đầu ra mong muốn quyết định bài toán thuộc nhóm nào. Buổi học tập trung vào Supervised Learning.

Classification (phân loại)

- ▶ Nhãn y là giá trị rời rạc (lớp/loại).
- ▶ Đầu ra: một trong các lớp cho trước.
- ▶ Ví dụ: sống sót / không sống sót; spam / không spam.

Regression (hồi quy)

- ▶ Nhãn y là giá trị liên tục.
- ▶ Đầu ra: một số thực.
- ▶ Ví dụ: giá nhà, nhiệt độ, doanh thu dự kiến.

Bài toán Titanic dự đoán *Survived* (sống / không) là một bài toán **classification**. Việc xác định nhóm bài toán quyết định lựa chọn mô hình và *metric đánh giá* (Phần 4).

➤ HOẠT ĐỘNG


Phản xạ thường gặp

Nhận được file `titanic.csv` và bắt tay **huấn luyện mô hình** ngay.

Thực tế của dữ liệu thô

- ▶ Age, Cabin thiếu nhiều giá trị.
- ▶ Fare có giá trị bất thường.
- ▶ Sex, Embarked ở dạng chữ.

Huấn luyện ngay trên dữ liệu thô cho kết quả sai lệch. Trước khi mô hình hóa cần một quy trình có thứ tự — đó là **pipeline** của một dự án Machine Learning.



Đặc điểm của pipeline

- ▶ Đây là quy trình **lặp** (iterative): kết quả đánh giá thường dẫn đến việc quay lại tinh chỉnh dữ liệu và mô hình.
- ▶ Phần lớn công sức nằm ở **EDA** và **Preprocessing** — trọng tâm của buổi học hôm nay.

Vai trò

- ▶ Thư viện Machine Learning tiêu chuẩn của hệ sinh thái Python.
- ▶ Cung cấp mô hình, công cụ tiền xử lý và metric đánh giá theo một giao diện thống nhất.

Giao diện nhất quán (API)

- ▶ `.fit()` — học từ dữ liệu.
- ▶ `.transform()` — biến đổi dữ liệu.
- ▶ `.predict()` — dự đoán trên dữ liệu mới.

Các module chính

- ▶ `preprocessing` — scaling, encoding.
- ▶ `impute` — xử lý missing value.
- ▶ `model_selection` — chia tập, cross-validation.
- ▶ `metrics` — các metric đánh giá.
- ▶ `linear_model`, `tree`, `ensemble` — các mô hình.

► QUIZ

Xác định nhóm bài toán

1. Netflix gợi ý phim tiếp theo cho người dùng.
2. Dự đoán hóa đơn tiền điện tháng tới (theo VNĐ).
3. Chia khách hàng thành các nhóm hành vi, không có nhãn sẵn.

► QUIZ

Xác định nhóm bài toán

1. Netflix gợi ý phim tiếp theo cho người dùng.
2. Dự đoán hóa đơn tiền điện tháng tới (theo VNĐ).
3. Chia khách hàng thành các nhóm hành vi, không có nhãn sẵn.

Đáp án: (1) Recommendation / Classification — Supervised; (2) Regression — Supervised; (3) Clustering — Unsupervised.

2

Khám phá dữ liệu (EDA)

Exploratory Data Analysis — hiểu dữ liệu trước khi mô hình hóa — 45 phút

► HOẠT ĐỘNG


Đoán trước khi xem

Trên Titanic, nhóm nào có tỷ lệ sống sót cao hơn và chênh lệch khoảng bao nhiêu — theo **giới tính** và theo **hạng vé**?

► HOẠT ĐỘNG

Đoán trước khi xem

Trên Titanic, nhóm nào có tỷ lệ sống sót cao hơn và chênh lệch khoảng bao nhiêu — theo **giới tính** và theo **hạng vé**?



Nữ 74% so với nam 19%; hạng vé 1 (63%) gần gấp 2,6 lần hạng 3 (24%). Trả lời các câu hỏi này một cách có hệ thống chính là EDA.

Một lát cắt dữ liệu Titanic

Age	Fare	Embarked
22	7.25	S
NaN	71.28	C
30	512.3	S
NaN	8.05	NaN

Các vấn đề lộ ra ngay

- ▶ Giá trị thiếu (NaN) ở nhiều cột.
- ▶ Giá trị bất thường (Fare = 512).
- ▶ Cột chữ (Embarked) mô hình chưa đọc được.


Ba vấn đề này — missing, outlier, dữ liệu dạng chữ — sẽ được xử lý ở Phần 3. EDA có nhiệm vụ phát hiện chúng.

Định nghĩa

EDA là bước phân tích và trực quan hóa dữ liệu nhằm *hiểu cấu trúc, chất lượng và các quy luật ban đầu* của dữ liệu trước khi xây dựng mô hình.

Bốn nội dung cần kiểm tra

Nội dung	Mục đích
Shape & dtype	Số mẫu, số đặc trưng và kiểu dữ liệu từng cột.
Missing value	Vị trí và tỷ lệ giá trị thiếu.
Outlier	Các giá trị bất thường, khác biệt lớn so với phần còn lại.
Distribution & correlation	Phân phối từng biến và quan hệ giữa các biến.



Vì sao phải xử lý


- ▶ Mô hình **không nhận trực tiếp** giá trị NaN.
- ▶ deck thiếu $\approx 77\%$ → cân nhắc **loại bỏ**.
- ▶ Age thiếu $\approx 20\%$ → **điền** (median).
- ▶ Embarked thiếu rất ít → điền **mode**.

Tỷ lệ thiếu quyết định cách xử lý; chi tiết ở Phần 3 — Tiền xử lý.

Trực giác: mean vs median

[20, 21, 22, 19, 450]

- ▶ Mean = 106.4 — bị 450 kéo lệch.
- ▶ Median = 21 — bền vững với outlier.



Fare có 116 outlier theo IQR, nhưng đó là **vé hạng nhất có thật**, không phải lỗi. Quyết định: *giữ lại* và dùng **RobustScaler** thay vì xóa.

Univariate

Phân tích **từng biến độc lập**.

- ▶ Phân phối, giá trị trung tâm, độ phân tán.
- ▶ Công cụ: histogram, boxplot.

Bivariate

Quan hệ giữa **hai biến**.

- ▶ Tương quan, xu hướng.
- ▶ Công cụ: scatter plot, boxplot theo nhóm.

Multivariate


Quan hệ giữa **nhiều biến**.

- ▶ Cấu trúc tương quan tổng thể.
- ▶ Công cụ: heatmap correlation, pair plot.

Mức độ phân tích tăng dần theo số biến được xem xét đồng thời.

➤ HOẠT ĐỘNG

Histogram — phân phối của một biến



Phân phối Fare của Titanic lệch trái hay lệch phải?


Boxplot — tứ phân vị & outlier



Thể hiện trung vị, tứ phân vị (quartile); điểm ngoài “râu” là outlier.

➤ HOẠT ĐỘNG

Histogram — phân phối của một biến




Phân phối Fare của Titanic lệch trái hay lệch phải?

Boxplot — tứ phân vị & outlier



Thể hiện trung vị, tứ phân vị (quartile); điểm ngoài “râu” là outlier.



Đọc heatmap tương quan Pearson $r \in [-1, 1]$

- ▶ r gần $+1$: tương quan dương mạnh (màu ấm).
- ▶ r gần -1 : tương quan âm mạnh (màu lạnh).
- ▶ r gần 0 : gần như không tương quan tuyến tính.

Trên Titanic, `Pclass` tương quan âm với `Fare` (hạng vé nhỏ $\rightarrow$ giá cao); scatter plot dùng để soi quan hệ giữa hai biến số liên tục.

► QUIZ

Tình huống

Một cột đặc trưng bị thiếu tới 90% số giá trị. Nên xử lý thế nào?

➤ QUIZ

Tình huống

Một cột đặc trưng bị thiếu tới 90% số giá trị. Nên xử lý thế nào?

Đáp án gợi ý: thường *loại bỏ cột* — điền giá trị cho 90% dữ liệu thiếu sẽ tạo ra thông tin giả. Chỉ giữ lại nếu cột đó đặc biệt quan trọng và có cách suy luận đáng tin (ví dụ Cabin trong Titanic thường bị loại hoặc rút gọn thành “có/không có thông tin cabin”).

3

Tiền xử lý dữ liệu

Data Preprocessing — biến dữ liệu thô thành dữ liệu mô hình học được — 45 phút



Mục tiêu của tiền xử lý

Biến dữ liệu thô thành dữ liệu **đầy đủ, dạng số và cùng thang đo**. Mỗi rào cản trên tương ứng một nhóm kỹ thuật: xử lý missing value, encoding, và scaling.

Các phương án phổ biến

- ▶ **Xóa (drop):** loại bỏ dòng/cột có quá nhiều giá trị thiếu.
- ▶ **Điền mean / median:** thay bằng trung bình hoặc trung vị của cột.
- ▶ **KNN Imputation:** ước lượng từ các mẫu lân cận gần nhất.

Trong Titanic

- ▶ Age: điền median hoặc KNN.
- ▶ Embarked: điền mode (thiếu rất ít).
- ▶ Cabin: loại bỏ (thiếu $\approx 77\%$).

Median ổn định hơn mean khi có outlier; KNN giữ được quan hệ giữa các biến nhưng tốn chi phí hơn.

Phương pháp IQR

$$IQR = Q_3 - Q_1$$

Outlier nếu nằm ngoài khoảng:

$$[Q_1 - 1.5 IQR, Q_3 + 1.5 IQR]$$

Phù hợp với dữ liệu không theo phân phối chuẩn.

Phương pháp Z-score

$$z = \frac{x - \mu}{\sigma}$$

Outlier khi $|z| > 3$ (ngưỡng thường dùng).

Giả định dữ liệu xấp xỉ phân phối chuẩn.

Không phải mọi outlier đều cần loại bỏ: một số phản ánh hiện tượng thực tế quan trọng. Quyết định xử lý phải dựa trên hiểu biết về bài toán.

Vì sao cần scaling — một phép tính

Hai hành khách, đặc trưng {tuổi, lương}:

$$P_1 = (20, 300,000,000)$$

$$P_2 = (60, 301,000,000)$$

Khoảng cách Euclid:

$$\sqrt{\underbrace{40^2}_{\text{tuổi}} + \underbrace{(10^6)^2}_{\text{lương}}} \approx 10^6$$

Chênh lệch tuổi (gấp 3 lần một đời người) gần như **biến mất** — khoảng cách hầu như do lương quyết định.

Kỹ thuật	Công thức	Đặc điểm
StandardScaler	$\frac{x - \mu}{\sigma}$	mean 0, std 1.
MinMaxScaler	$\frac{x - x_{\min}}{x_{\max} - x_{\min}}$	về [0, 1]; nhạy outlier
RobustScaler	$\frac{x - \text{med}}{\text{IQR}}$	bền vững outlier.

Scaling đưa các đặc trưng về cùng thang để đóng góp cân bằng. Cần cho KNN, SVM, hồi quy có regularization, mạng nơ-ron.

Vấn đề: mô hình không đọc được dữ liệu dạng chữ

Cột $\text{Sex} \in \{\text{male}, \text{female}\}$ và $\text{Embarked} \in \{\text{S}, \text{C}, \text{Q}\}$ của Titanic cần được chuyển thành số.

Kỹ thuật	Cách mã hóa	Sử dụng khi
Label Encoding	Red=0, Blue=1, Green=2	Cần dạng số; lưu ý tạo ra thứ tự giả (Green > Blue).
One-Hot Encoding	Red=100, Blue=010, Green=001	Biến <i>nominal</i> không thứ tự, ít giá trị (Embarked).
Ordinal Encoding	Small<Medium<Large	Biến <i>ordinal</i> có thứ tự tự nhiên.

One-Hot tránh được thứ tự giả của Label Encoding trên biến không có thứ tự.

Vai trò của từng tập

- ▶ **Train:** huấn luyện mô hình.
- ▶ **Validation:** tinh chỉnh siêu tham số, chọn mô hình.
- ▶ **Test:** đánh giá cuối cùng, chỉ dùng một lần.

Tỷ lệ thường dùng: 70/15/15 hoặc 80/10/10; dữ liệu càng lớn, phần test có thể càng nhỏ.

Train (70%)

Val

Test

Data Leakage: nếu thông tin từ tập test rò rỉ vào huấn luyện, kết quả đánh giá không còn phản ánh năng lực thực sự — tương tự việc biết trước đề thi.

✗ SAI

Học tham số tiền xử lý (median để điền, min/max/IQR để scale) trên **toàn bộ** dữ liệu, rồi mới chia tập.

⇒ Thông tin của tập test đã *rò rỉ* vào tham số dùng cho train.

✓ ĐÚNG

Chia tập trước. Học mọi tham số tiền xử lý **chỉ trên train**, rồi áp cùng phép biến đổi đó cho validation và test.

⇒ Test đóng vai “dữ liệu tương lai chưa từng thấy”.

Leakage khiến điểm đánh giá cao ảo trên giấy nhưng mô hình thất bại khi triển khai thực tế.

► QUIZ

Với Titanic, chọn kỹ thuật phù hợp

1. Embarked (S / C / Q) — encoding nào?
2. Fare (0 đến 512) — có cần scaling không?
3. Sex (male / female) — encoding nào?

► QUIZ

Với Titanic, chọn kỹ thuật phù hợp


1. Embarked (S / C / Q) — encoding nào?
2. Fare (0 đến 512) — có cần scaling không?
3. Sex (male / female) — encoding nào?

Đáp án: (1) One-Hot (nominal, 3 giá trị); (2) Có — thang đo rộng, cần chuẩn hóa; (3) Label / nhị phân (hai giá trị).

4

Đánh giá mô hình

Khung lý thuyết chung: metric & Cross-Validation — 45 phút



Ba trạng thái

- ▶ **Underfitting:** quá đơn giản, sai số cao ở cả train và validation.
- ▶ **Good fit:** sai số thấp và cân bằng.
- ▶ **Overfitting:** khớp cả nhiều của train; sai số validation tăng.

Bias cao dẫn đến underfitting; variance cao dẫn đến overfitting. Đánh giá mô hình nhằm cân bằng hai yếu tố này (bias–variance tradeoff).

Metric	Công thức	Ý nghĩa
MAE	$\frac{1}{n} \sum_i y_i - \hat{y}_i $	Sai số tuyệt đối trung bình; ít nhạy với outlier.
MSE	$\frac{1}{n} \sum_i (y_i - \hat{y}_i)^2$	Phạt nặng sai số lớn; đơn vị bình phương.
RMSE	$\sqrt{\text{MSE}}$	Cùng đơn vị với biến mục tiêu.
R^2	$1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$	Tỷ lệ phương sai được mô hình giải thích; càng gần 1 càng tốt.

Trong dự đoán giá nhà, sai số 100 triệu nghiêm trọng hơn nhiều so với 10 triệu: MSE và RMSE phạt nặng sai số lớn, trong khi MAE xem mọi sai số theo tỷ lệ tuyến tính.

Ví dụ: sàng lọc bệnh

- ▶ 1000 bệnh nhân: 990 khỏe, 10 mắc bệnh.
- ▶ Mô hình luôn dự đoán “khỏe”.
- ▶ $\text{Accuracy} = 990/1000 = 99\%$.

Có nên triển khai mô hình này?

Metric phải được chọn theo bản chất và chi phí sai lầm của bài toán.

Ví dụ: sàng lọc bệnh

- ▶ 1000 bệnh nhân: 990 khỏe, 10 mắc bệnh.
- ▶ Mô hình luôn dự đoán “khỏe”.
- ▶ $\text{Accuracy} = 990/1000 = 99\%$.

Có nên triển khai mô hình này?

Vấn đề

- ▶ Mô hình bỏ sót **toàn bộ** ca bệnh ($\text{Recall} = 0$).
- ▶ Accuracy cao nhưng vô dụng với mục tiêu bài toán.
- ▶ Dữ liệu mất cân bằng cần Precision, Recall, F1-score.

Metric phải được chọn theo bản chất và chi phí sai lầm của bài toán.

Sàng lọc bệnh — với số thật

	DĐ bệnh	DĐ khỏe
Thật bệnh	TP= 8	FN= 2
Thật khỏe	FP= 15	TN= 975

Một mô hình bắt được 8/10 ca bệnh, nhưng báo nhầm 15 người khỏe.

Tính ra con số cụ thể

$$\text{Accuracy} = \frac{8+975}{1000} = 98.3\%$$

$$\text{Precision} = \frac{TP}{TP+FP} = \frac{8}{23} = 0.35$$

$$\text{Recall} = \frac{TP}{TP+FN} = \frac{8}{10} = 0.80$$

$$F_1 = \frac{2 \cdot 0.35 \cdot 0.80}{0.35 + 0.80} = 0.49$$

Accuracy 98,3% trông rất cao, nhưng Precision chỉ 0,35 — cứ 3 ca báo bệnh thì 2 là báo nhầm. **Precision** khi chi phí báo nhầm cao; **Recall** khi chi phí bỏ sót cao; **F1** cân bằng cả hai.

Bài toán	Metric ưu tiên	Lý do
Chẩn đoán bệnh (hospital)	Recall	Tránh bỏ sót ca bệnh.
Nhận diện khuôn mặt ở sân bay	Precision	Tránh báo nhầm danh tính.
Phát hiện gian lận (fraud)	Recall / PR-AUC	Dữ liệu cực kỳ mất cân bằng.
Hệ thống gợi ý (recommendation)	MAP@k / NDCG	Quan tâm thứ hạng của gợi ý.


Metric được chọn theo chi phí của từng loại sai lầm trong bài toán cụ thể, không có lựa chọn tối ưu chung.

		Dự đoán	
		Positive	Negative
Thực tế	Positive	TP	FN
	Negative	FP	TN

Bốn ô kết quả

- ▶ **TP** — dự đoán đúng lớp positive.
- ▶ **TN** — dự đoán đúng lớp negative.
- ▶ **FP** — báo positive sai (false alarm).
- ▶ **FN** — bỏ sót positive (miss).

Toàn bộ metric phân loại đều được suy ra từ bốn giá trị này.



Ý nghĩa

- ▶ ROC biểu diễn quan hệ giữa True Positive Rate và False Positive Rate qua các ngưỡng phân loại.
- ▶ **AUC** (diện tích dưới đường cong) $\in [0, 1]$: đo khả năng phân biệt hai lớp.
- ▶ $AUC = 0.5$ tương đương đoán ngẫu nhiên; đường cong càng ôm sát góc trên bên trái càng tốt.

Hold-out Validation

Chia dữ liệu một lần thành train và validation cố định.

- ▶ Đơn giản, nhanh.
- ▶ Kết quả phụ thuộc cách chia; phương sai ước lượng cao khi dữ liệu ít.

K-Fold Cross-Validation

Chia dữ liệu thành K phần; lần lượt dùng một phần để kiểm định, phần còn lại để huấn luyện, rồi lấy trung bình kết quả.

- ▶ Ước lượng ổn định hơn.
- ▶ Tốn nhiều lần huấn luyện hơn.



➤ QUIZ

Tình huống

Một mô hình đạt Accuracy 99% trên bài toán phát hiện gian lận thẻ tín dụng (fraud). Có thể kết luận mô hình tốt không?

► QUIZ

Tình huống

Một mô hình đạt Accuracy 99% trên bài toán phát hiện gian lận thẻ tín dụng (fraud). Có thể kết luận mô hình tốt không?

Đáp án: Chưa thể. Gian lận là lớp hiếm; một mô hình luôn dự đoán “không gian lận” cũng đạt Accuracy rất cao. Cần xem Recall, Precision và PR-AUC.

5

Thực hành

EDA & Preprocessing đầy đủ trên dataset Titanic

Bối cảnh dữ liệu

Dataset Titanic ghi nhận thông tin hành khách và kết quả sống sót sau thảm họa. Đây là bài toán **classification** với biến mục tiêu Survived (0 / 1).

Một số đặc trưng chính

- ▶ Pclass — hạng vé (1/2/3).
- ▶ Sex, Age — giới tính, tuổi.
- ▶ SibSp, Parch — số người thân đi cùng.
- ▶ Fare — giá vé; Embarked — cảng lên tàu.

Đặc điểm cần lưu ý

- ▶ Nhiều giá trị thiếu ở Age và Cabin.
- ▶ Có cả biến số và biến phân loại.
- ▶ Biến mục tiêu *mất cân bằng* nhẹ giữa hai lớp.

Mục tiêu buổi thực hành: hoàn thành EDA & tiền xử lý — chưa huấn luyện mô hình.

➤ HOẠT ĐỘNG

Mỗi nhóm khám phá Titanic và tìm

- ▶ **3 cột** có giá trị thiếu và đề xuất cách xử lý cho mỗi cột.
- ▶ **2 giá trị outlier** (gợi ý: quan sát `Fare`, `Age`).
- ▶ **1 đặc trưng** có vẻ quan trọng nhất với khả năng sống sót, kèm lý do.

Kết quả của nhóm sẽ là điểm khởi đầu cho notebook nộp về nhà.

EDA

1. Quan sát dataset: số đặc trưng, biến mục tiêu.
2. Kiểm tra `shape`, `info`, `describe`.
3. Thống kê missing value & đề xuất cách xử lý.
4. Phát hiện outlier (IQR / Z-score).
5. Trực quan hóa: histogram, boxplot, scatter, heatmap.

Preprocessing & kết luận

6. Encoding: cột nào One-Hot, cột nào Label.
7. Scaling: cột nào cần chuẩn hóa.
8. Chia tập train / validation / test.
9. Viết nhận xét về dữ liệu.

Nộp bài: notebook `titanic_eda_preprocessing.ipynb` kèm phần nhận xét, nộp qua **GitHub** (repo cá nhân từ repo mẫu).

Các câu hỏi cần trả lời trong nhận xét

- ▶ Đặc trưng nào có tương quan rõ nhất với khả năng sống sót?
- ▶ Cột nào thiếu dữ liệu nhiều nhất, và phương án xử lý đã chọn là gì?
- ▶ Biến mục tiêu có mất cân bằng không, và điều đó ảnh hưởng thế nào đến việc chọn metric?
- ▶ Đặc trưng nào cần scaling, đặc trưng nào cần encoding, và vì sao?

Nhận xét cần dựa trên bằng chứng trực quan và số liệu thu được từ EDA.



Một mô hình mạnh không thể bù đắp cho một bộ dữ liệu kém chất lượng.

Machine Learning

≠

Training Model

Huấn luyện mô hình chỉ là một bước trong toàn bộ quy trình.



Data & EDA — 70%

Thu thập, hiểu và làm sạch dữ liệu.

Feature Engineering — 20%

Biến đổi và tạo đặc trưng phù hợp.

Model — 10%

Lựa chọn và huấn luyện mô hình.

Chất lượng dữ liệu và đặc trưng quyết định phần lớn kết quả của một dự án ML.

Nội dung chính

- ▶ Machine Learning học quy luật từ dữ liệu; phân loại thành Supervised, Unsupervised, Reinforcement.
- ▶ Pipeline chuẩn: Data → EDA → Preprocessing → Model → Evaluate → Deploy.
- ▶ EDA và tiền xử lý quyết định phần lớn chất lượng của một dự án ML.
- ▶ Metric đánh giá phải được chọn theo bản chất bài toán.

Buổi 6

Linear Regression: mô hình hồi quy tuyến tính, Gradient Descent, huấn luyện mô hình đầu tiên trên dữ liệu Titanic đã tiền xử lý.

Lưu ý: hoàn thành notebook Titanic trước buổi học tiếp theo.

Thank You

Acknowledgements

Cảm ơn các bạn học viên. Buổi học đã đi qua toàn bộ chặng đầu của một dự án Machine Learning: từ hiểu dữ liệu đến chuẩn bị dữ liệu cho mô hình. Hẹn gặp lại ở Buổi 6 — Linear Regression.