

Linear Regression

Minh Nguyen Chu^{*a}

^aMachine Learning & IoT Lab, HCMUT

Email: chuminh.nguyen.podd@gmail.com

Machine Learning & IoT Lab (ML IoT)
Ho Chi Minh City University of Technology (HCMUT)

1. Thiết lập bài toán Regression
2. Nền tảng toán học & optimization
3. Giả định mô hình và diagnostics
4. Regularization: Ridge, Lasso, Elastic Net
5. Quy trình thực hành và evaluation
6. Ứng dụng Thực chiến: Statistical Arbitrage

Kết quả học tập

Sau bài học này, sinh viên có thể:

- ▶ Biểu diễn Regression dưới dạng ma trận.
- ▶ Suy ra OLS từ Gaussian MLE.
- ▶ So sánh closed-form và iterative optimization.
- ▶ Giải thích vì sao Regularization giúp ổn định learning.

Định nghĩa bài toán

- ▶ Regression là bài toán supervised learning dùng để dự đoán biến mục tiêu liên tục.
- ▶ Đầu vào là các biến độc lập, còn gọi là features hoặc predictors.
- ▶ Mô hình học hàm $f(x)$ sao cho $\hat{y} = f(x)$ gần với giá trị thật y .

Regression so với Classification

- ▶ Regression: dự đoán giá trị số trên thang liên tục.
- ▶ Classification: dự đoán lớp hoặc nhãn rời rạc.

Ví dụ: giá nhà, doanh thu, nhiệt độ, nhu cầu, mức tiêu thụ năng lượng.

❶ Dự đoán giá nhà

- ▶ Target: giá trị thị trường của một căn nhà.
- ▶ Features: diện tích, số phòng ngủ, vị trí, tuổi nhà, mức thu nhập.

❷ Dự báo doanh thu

- ▶ Target: doanh thu bán hàng trong tương lai.
- ▶ Features: chi phí quảng cáo, mùa vụ, khuyến mãi, lưu lượng khách hàng.

❸ Dự đoán nhiệt độ

- ▶ Target: nhiệt độ môi trường.
- ▶ Features: độ ẩm, áp suất, mây che phủ, thời điểm trong ngày.

Ý tưởng chính: linear regression liên kết các đầu vào đo được với đầu ra dạng số bằng một phương trình đơn giản và dễ diễn giải.

Mô hình tổng quát

$$y = Xw + \epsilon$$

- ▶ Xem simple regression và multiple regression như một bài toán linear algebra thống nhất.
- ▶ Vector dự đoán là $\hat{y} = Xw$.

Design Matrix

$$X \in \mathbb{R}^{n \times (d+1)}$$

- ▶ n : số lượng training samples.
- ▶ d : số lượng features gốc.
- ▶ Cột đầu tiên: $x_0 = 1$ cho bias term.

Vector tham số và nhiễu

$$w \in \mathbb{R}^{(d+1) \times 1},$$
$$\epsilon \in \mathbb{R}^{n \times 1}$$

- ▶ w chứa bias và feature weights.
- ▶ ϵ mô hình hóa sai số ngẫu nhiên chưa giải

Mục tiêu MSE

$$J(w) = \frac{1}{2n} \|Xw - y\|_2^2$$

- ▶ Đo khoảng cách Euclidean bình phương giữa predictions và targets.
- ▶ Hệ số $1/(2n)$ làm gradient gọn hơn mà không đổi nghiệm tối ưu.

Giả định Gaussian Noise

$$\epsilon_i \sim \mathcal{N}(0, \sigma^2)$$
$$p(y_i | x_i; w) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(y_i - x_i^T w)^2}{2\sigma^2} \right]$$

Từ Likelihood đến Log-Likelihood

$$L(w) = \prod_{i=1}^n p(y_i | x_i; w),$$

$$\log L(w) = C - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - x_i^T w)^2.$$

- ▶ C là hằng số theo w .
- ▶ Tối đa hóa $\log L(w)$ tương đương với tối thiểu hóa squared error.
- ▶ Vì vậy, OLS là MLE dưới giả định Gaussian residual noise.

Suy diễn Closed-form

$$J(w) = \frac{1}{2} (w^T X^T X w - 2w^T X^T y + y^T y),$$

$$\nabla_w J(w) = X^T X w - X^T y.$$

- ▶ Đặt $\nabla_w J(w) = 0$.
- ▶ Giải normal equation $X^T X w = X^T y$.

$$w = (X^T X)^{-1} X^T y$$

Diễn giải hình học

- ▶ $\hat{y} = Xw$ nằm trong column space của X .
- ▶ OLS chọn phép chiếu trực giao của y lên $\text{Col}(X)$.
- ▶ Residual vector $y - \hat{y}$ trực giao với mọi cột của X .

Hạn chế

- ▶ Matrix inversion có chi phí khoảng $O(d^3)$.
- ▶ Multicollinearity có thể làm $X^T X$ suy biến hoặc ill-conditioned.

Phương án Iterative

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \alpha \frac{1}{n} \mathbf{X}^T (\mathbf{X} \mathbf{w}^{(t)} - \mathbf{y})$$

- ▶ Cần thiết khi feature matrix quá lớn để nghịch đảo giải tích một cách ổn định.
- ▶ Sử dụng gradient của $\frac{1}{2n} \|\mathbf{X} \mathbf{w} - \mathbf{y}\|_2^2$.

Ý nghĩa toán học

- ▶ $\mathbf{X} \mathbf{w}^{(t)} - \mathbf{y}$ là error vector hiện tại.
- ▶ $\mathbf{X}^T(\cdot)$ phân phối error ngược về các hướng feature.
- ▶ Bước cập nhật đi ngược hướng tăng loss dốc nhất tại điểm hiện tại.

Learning Rate α

- ▶ Điều khiển step size của mỗi lần cập nhật.
- ▶ Quá nhỏ: convergence chậm.
- ▶ Quá lớn: dao động hoặc divergence.
- ▶ Feature Scaling giúp convergence ổn định hơn.

Giả định thống kê

1. Linearity: $\mathbb{E}[y | X] = Xw$.
2. Independence: residuals không tương quan chuỗi.
3. Homoscedasticity: $\text{Var}(\epsilon_i) = \sigma^2$ là hằng số.
4. Normality: residuals xấp xỉ Gaussian để phục vụ inference.

Diagnostics

- ▶ Residual-vs-fitted plots kiểm tra nonlinearity và heteroscedasticity.
- ▶ Q-Q plots đánh giá normality của residuals.
- ▶ Correlation matrices và VIF phát hiện multicollinearity.
- ▶ Outlier và leverage analysis tìm các samples có ảnh hưởng mạnh.

Residual: $e_i = y_i - \hat{y}_i$.

Định nghĩa

- ▶ Multicollinearity xảy ra khi các biến độc lập predictors có tương quan tuyến tính cao với nhau.
- ▶ Khi đó, nhiều cột của ma trận thiết kế X mang thông tin gần như trùng lặp.
- ▶ Mô hình vẫn có thể dự đoán tốt, nhưng việc diễn giải riêng từng hệ số trở nên rủi ro.

Tác động lên OLS

$$\hat{w} = (X^T X)^{-1} X^T y$$

- ▶ Tương quan cao làm $\det(X^T X) \approx 0$.
- ▶ Ma trận $(X^T X)^{-1}$ trở nên bất ổn hoặc không tồn tại.
- ▶ Phương sai hệ số có thể bùng nổ:

$$\text{Var}(\hat{w}) = \sigma^2 (X^T X)^{-1}$$

Hệ quả: hệ số rất nhạy với nhiễu nhỏ trong dữ liệu, dấu bất thường, khoảng tin cậy rộng và mất khả năng diễn giải cá nhân.

Nguyên nhân phổ biến

- ▶ Tương quan nội tại: các biến đo cùng một hiện tượng thực tế.
- ▶ Dummy Variable Trap: one-hot encoding nhưng quên bỏ cột baseline.
- ▶ Feature Engineering sai cách: tạo biến mới gần như là tổ hợp tuyến tính của biến cũ.

Variance Inflation Factor

- ▶ Với mỗi X_j , chạy hồi quy phụ: dự đoán X_j bằng tất cả predictors còn lại.
- ▶ Gọi R_j^2 là độ khớp của hồi quy phụ đó:

$$VIF_j = \frac{1}{1 - R_j^2}$$

- ▶ $R_j^2 \rightarrow 1$ làm $VIF_j \rightarrow \infty$.

Mức VIF	Diễn giải thực hành
$VIF = 1$	Không có tương quan tuyến tính với predictors còn lại.
$VIF > 5$	Multicollinearity mức vừa; cần thận trọng khi diễn giải hệ số.
$VIF > 10$	Multicollinearity nghiêm trọng; phương sai hệ số bị phóng đại mạnh và ước lượng kém tin cậy.

Loại bỏ biến

- ▶ Giữ feature có tương quan mạnh hơn với target y .
- ▶ Bỏ feature dư thừa khi ý nghĩa nghiệp vụ trùng lặp.
- ▶ Kiểm tra lại VIF sau mỗi vòng loại bỏ.

Gộp biến

- ▶ Chuyển các đại lượng tuyệt đối thành tỷ lệ hoặc trung bình.
- ▶ Ví dụ: diện tích mỗi phòng, thu nhập mỗi người, mật độ sử dụng.
- ▶ Giữ tín hiệu nhưng giảm trùng lặp tuyến tính.

Regularization

- ▶ Ridge: co hệ số về gần 0, ổn định nghiệm khi predictors tương quan.
- ▶ Lasso: ép hệ số dư thừa đúng bằng 0 để tự động chọn feature.
- ▶ Cần chuẩn hóa feature trước khi dùng regularization.

Vì sao mô hình vẫn là Linear?

- ▶ Linear nghĩa là tuyến tính theo tham số w , không bắt buộc tuyến tính theo input features x .
- ▶ Ta có thể biến đổi x thành $\phi(x)$ rồi vẫn huấn luyện bằng OLS:

$$y = w_0 + w_1 \phi_1(x) + \dots + w_p \phi_p(x) + \epsilon$$

domain-specific features

- ▶ Dùng tri thức ngành để tạo tín hiệu gần hơn với cơ chế sinh dữ liệu.
- ▶ Ưu tiên feature dễ giải thích và đo lường ổn định.

interaction features

- ▶ Mô hình hóa hiệu ứng cộng hưởng giữa hai predictors.
- ▶ Dạng cơ bản: $x_{\text{new}} = x_1 x_2$.

polynomial features

- ▶ Thêm $x^2, x^3, \dots$ để bắt xu hướng cong.
- ▶ Cần kiểm soát độ phức tạp để tránh overfitting.

domain-specific features

- ▶ Tạo biến từ tri thức ngành thay vì chỉ nạp dữ liệu thô.
- ▶ Ví dụ nhà ở: bedroom-to-occupant density phản ánh chất lượng không gian sống tốt hơn số phòng ngủ riêng lẻ.
- ▶ Ví dụ tổng quát: $\text{density} = \frac{\text{bedrooms}}{\text{occupants}}$.

interaction features

- ▶ Bất hiệu ứng phối hợp: tác động của x_1 phụ thuộc vào mức của x_2 .

- ▶ Thêm tích x_1x_2 vào mô hình:

$$y = w_0 + w_1x_1 + w_2x_2 + w_3(x_1x_2) + \epsilon$$

$$\frac{\partial y}{\partial x_1} = w_1 + w_3x_2$$

- ▶ Vì vậy hiệu ứng biên của x_1 thay đổi động theo x_2 .

polynomial features

- ▶ Thêm bậc cao $x^2, x^3, \dots$ để mô hình hóa quan hệ phi tuyến nhưng vẫn tuyến tính theo w .

- ▶ Ví dụ một biến:

$$y = w_0 + w_1x + w_2x^2 + w_3x^3 + \epsilon$$

- ▶ Hữu ích khi dữ liệu có điểm cực trị, ngưỡng bão hòa hoặc xu hướng cong.

Cảnh báo overfitting

- ▶ Thêm feature phức tạp thường làm training error giảm.
- ▶ Nếu thêm quá nhiều, mô hình có thể học cả nhiễu thay vì quy luật.
- ▶ Dấu hiệu điển hình: training error thấp nhưng test error cao.
- ▶ Cần dùng validation, cross-validation và regularization để kiểm soát độ phức tạp.

Cần nói: Feature Engineering tăng bias–variance flexibility; regularization giúp giữ mô hình đủ linh hoạt nhưng không ghi nhớ noise.

Khái niệm & biểu hiện

- ▶ Overfitting: mô hình quá linh hoạt ghi nhớ nhiều của tập train thay vì học quy luật tổng quát.
- ▶ Biểu hiện điển hình: training error rất thấp nhưng test error tăng mạnh, dẫn đến generalization kém.
- ▶ Trong hồi quy bậc cao hoặc nhiều feature, đường dự đoán có thể uốn lượn để đi qua cả các điểm nhiễu.

Dấu hiệu toán học

- ▶ Các hệ số w_j có thể phình lớn bất thường để bù trừ nhau và khớp nhiễu.
- ▶ Khi $\|w\|$ quá lớn, dự đoán trở nên nhạy với thay đổi nhỏ của dữ liệu đầu vào.

$$\text{Loss} = \text{MSE} + \text{Penalty}(w)$$

- ▶ Regularization: thêm Penalty term để hạn chế hệ số lớn không cần thiết và ưu tiên mô hình đơn giản hơn.

Công thức toán học

$$J(w) = \frac{1}{n} \|y - Xw\|_2^2 + \alpha \sum_{j=1}^d w_j^2 = \text{MSE} + \alpha \|w_{1:d}\|_2^2$$

Hệ số bias w_0 không bị phạt; chỉ các trọng số feature $w_1, \dots, w_d$ nằm trong Penalty term.

Giải pháp Closed-form

$$w_{\text{Ridge}} = (X^T X + n\alpha I)^{-1} X^T y$$

Ma trận $n\alpha I$ làm tăng đường chéo của $X^T X$, giúp nghiệm ổn định hơn.

Tác động cốt lõi

- ▶ Giảm vấn đề hệ số nổ do Multicollinearity hoặc ma trận gần suy biến.
- ▶ Co các hệ số về gần 0 nhưng thường không làm chúng đúng bằng 0.
- ▶ Phù hợp khi nhiều feature đều có tín hiệu và cần giữ tính ổn định.

Công thức toán học

$$J(w) = \frac{1}{n} \|y - Xw\|_2^2 + \alpha \sum_{j=1}^d |w_j| = \text{MSE} + \alpha \|w_{1:d}\|_1$$

Đặc tính hình học & Sparsity

- ▶ Ràng buộc L_1 tạo miền nghiệm dạng hình thoi / đa diện với nhiều góc nhọn.
- ▶ Đường đồng mức của MSE dễ chạm các góc này, nơi một hoặc nhiều $w_j = 0$.
- ▶ Vì vậy Lasso tạo Sparsity: nghiệm chỉ giữ lại một tập nhỏ feature quan trọng.

Tác động cốt lõi

- ▶ Tự động Feature Selection bằng cách loại bỏ feature không liên quan hoặc dư thừa.
- ▶ Làm mô hình dễ diễn giải hơn khi số chiều d lớn.
- ▶ Có thể không ổn định khi nhiều feature tương quan mạnh với nhau.

Hạn chế của Lasso

Khi nhiều feature tương quan mạnh, Lasso có thể chọn tùy ý một feature và ép các feature còn lại về 0, làm mất thông tin cấu trúc nhóm.

Công thức phối hợp

Elastic Net kết hợp L_1 và L_2 penalties thông qua mixing ratio $r \in [0, 1]$:

$$J(w) = \text{MSE} + r\alpha \sum_{j=1}^d |w_j| + \frac{1-r}{2} \alpha \sum_{j=1}^d w_j^2$$

- ▶ $r = 1$: gần với Lasso; ưu tiên Sparsity và Feature Selection.
- ▶ $r = 0$: gần với Ridge; ưu tiên ổn định hệ số khi feature tương quan.
- ▶ $0 < r < 1$: giữ Sparsity của Lasso đồng thời thừa hưởng độ ổn định của Ridge cho nhóm feature tương quan.

Vai trò của α

- ▶ α điều khiển độ mạnh của Penalty term.
- ▶ $\alpha = 0$: quay về OLS, không có Regularization.
- ▶ α quá lớn: hệ số bị co quá mạnh, mô hình Underfitting.

Bước 1: Feature Scaling

Chuẩn hóa Z-score để mọi feature có thang đo công bằng:

$$x'_j = \frac{x_j - \mu_j}{\sigma_j}$$

Bước 2: K-Fold Cross-Validation & Grid Search

1. Tạo lưới mũ cho α : $\{10^{-4}, 10^{-3}, \dots, 10^3\}$.
2. Chia training data thành K folds; mỗi lần dùng K - 1 folds để train và 1 fold để validation.
3. Tính trung bình validation MSE hoặc R^2 :

$$\overline{\text{MSE}}_{\text{val}}(\alpha) = \frac{1}{K} \sum_{k=1}^K \text{MSE}_k(\alpha)$$

4. Chọn $\alpha^* = \arg \min_{\alpha} \overline{\text{MSE}}_{\text{val}}(\alpha)$ để tối ưu generalization.

Kịch bản thiết lập & bơm Multicollinearity

- ▶ Dataset: dùng California Housing để dự đoán giá nhà trung vị.
- ▶ Từ feature gốc MedInc, sinh MedInc_Fake1 và MedInc_Fake2 bằng Gaussian Noise cực nhỏ.
- ▶ Feature Scaling: bắt buộc dùng StandardScaler trước Ridge Regression và Lasso Regression.

Đúc kết thực hành


- ▶ R^2 trên Test set có thể gần giống nhau, nhưng cấu trúc mô hình rất khác.
- ▶ Regularization cứu ý nghĩa vật lý của Coefficients khỏi Multicollinearity nghiêm trọng.
- ▶ Ridge ổn định cụm feature tương quan; Lasso tạo Sparsity để chọn feature gốc.

Bảng so sánh Coefficients trực quan

Feature	OLS	Ridge L ₂	Lasso L ₁
MedInc	+184.73	+0.286	+0.731
MedInc_Fake1	-351.42	+0.284	0.0000
MedInc_Fake2	+167.11	+0.283	0.0000




Cách đọc kết quả


- ▶ OLS (Linear Regression): Coefficients nổ thành giá trị trái dấu rất lớn do ma trận gần suy biến.
- ▶ Ridge Regression: chia đều trọng số trong cụm tương quan và shrink an toàn về gần 0.
- ▶ Lasso Regression: ép MedInc_Fake1, MedInc_Fake2 về đúng 0.0000 để tự động Feature Selection.



Predicted vs Actual trên Test set

□ So Sánh Giá Trị Thực Tế vs. Dự Đoán — 3 Mô Hình





Khái niệm

- ▶ Khai thác quan hệ tuyến tính giữa hai tài sản tương đồng, ví dụ Coca-Cola (KO) và Pepsi (PEP).
- ▶ Giá riêng lẻ thường non-stationary; tổ hợp tuyến tính có thể tạo residuals stationary.
- ▶ Giao dịch độ lệch tạm thời của spread thay vì dự đoán hướng thị trường tuyệt đối.

Rolling OLS

$$\ln(\text{Price}_{\text{KO}}) = \beta \ln(\text{Price}_{\text{PEP}}) + \alpha + \epsilon$$

- ▶ OLS trên cửa sổ trượt để ước lượng hedge ratio β .
- ▶ Residual ϵ là spread đã giảm rủi ro thị trường chung.

Tín hiệu giao dịch bằng Z-score

$$Z = \frac{\epsilon - \mu_{\epsilon}}{\sigma_{\epsilon}}$$

- ▶ $Z > 2$: KO quá đắt so với PEP $\rightarrow$ bán khống KO, mua PEP.
- ▶ $Z < -2$: KO quá rẻ so với PEP $\rightarrow$ mua KO, bán khống PEP.
- ▶ Đóng vị thế khi spread hội tụ về trung bình: $Z \approx 0$.

Ý nghĩa ML: Linear Regression tạo residual signal có thể kiểm định, chuẩn hóa và chuyển thành quyết định giao dịch.



- ▶ Matrix formulation thống nhất simple regression và multiple regression dưới dạng $y = Xw + \epsilon$.
- ▶ Gaussian MLE cung cấp cơ sở lý thuyết cho việc tối thiểu hóa squared residuals.
- ▶ Normal equations cho nghiệm closed-form khi $X^T X$ khả nghịch và well-conditioned.
- ▶ Gradient descent mở rộng optimization cho feature matrices lớn thông qua iterative updates.
- ▶ Regularization cải thiện generalization bằng cách hạn chế hệ số bất ổn hoặc lớn không cần thiết.

Thông điệp chính: Linear regression vừa là statistical model vừa là optimization problem; Regularization giúp mô hình robust khi dữ liệu nhiễu, high-dimensional hoặc correlated.

- [1] Nguyễn Chu Minh. (2026). Linear Regression and Regularization. Nội dung bài giảng, Machine Learning & IoT Lab.
- [2] Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, pp. 2825–2830.
- [3] James, G., Witten, D., Hastie, T., Tibshirani, R., Taylor, J. (2023). An Introduction to Statistical Learning with Applications in Python. Springer.

Thank You

Acknowledgements

Xin cảm ơn. Mời đặt câu hỏi và thảo luận.