

Logistic Regression & K-Nearest Neighbors

Phan Quoc Dai Son^{*a}

^a Machine Learning & IoT Lab, HCMUT

*Email: sonphan0202@gmail.com

Machine Learning & IoT Lab (ML IoT)
Ho Chi Minh City University of Technology (HCMUT)

1. Tổng quan bài toán phân loại: nhị phân, đa lớp, ứng dụng
2. Logistic Regression: sigmoid, log loss, ngưỡng quyết định
3. K-Nearest Neighbors: khoảng cách, chọn k, chuẩn hóa dữ liệu
4. Đánh giá mô hình: confusion matrix, precision, recall, F1-score
5. Thực hành: dự đoán sống sót Titanic
6. Tổng kết, thảo luận và hỏi đáp

Contact Information

Address: 403.1 BK.B6, HCMUT Campus 2

Email:

nkloi@hcmut.edu.vn

mlandiotlab@gmail.com

Website: mliotlab.com

Facebook: facebook.com/hcmut.ml.iot.lab

YouTube: youtube.com/@mliotlab

Định nghĩa

- ▶ Phân loại là bài toán supervised learning dùng để dự đoán nhãn của dữ liệu.
- ▶ Đầu vào là các đặc trưng của đối tượng.
- ▶ Đầu ra là một lớp hoặc một nhãn rời rạc.

Ví dụ đơn giản

- ▶ Email → spam hoặc không spam.
- ▶ Giao dịch → gian lận hoặc bình thường.
- ▶ Hoa Iris → setosa, versicolor hoặc virginica.

Regression

- ▶ Dự đoán giá trị số liên tục.
- ▶ Output có thể là bất kỳ giá trị thực nào.
- ▶ Ví dụ: giá nhà, doanh thu, nhiệt độ.

Classification

- ▶ Dự đoán nhãn hoặc lớp.
- ▶ Output là giá trị rời rạc.
- ▶ Ví dụ: bệnh/không bệnh, sống sót/không sống sót.

Phân loại nhị phân

- ▶ Bài toán chỉ có hai lớp đầu ra.
- ▶ Thường ký hiệu nhãn là 0 và 1.
- ▶ Ví dụ: spam/not spam, fraud/normal.

Phân loại đa lớp

- ▶ Bài toán có từ ba lớp trở lên.
- ▶ Mỗi mẫu chỉ thuộc về một lớp chính.
- ▶ Ví dụ: phân loại hoa Iris thành ba loài.

Trong kinh doanh và công nghệ


- ▶ Phát hiện giao dịch gian lận.
- ▶ Phân loại email spam.
- ▶ Dự đoán khách hàng có rời bỏ dịch vụ hay không.

Trong y tế và đời sống

- ▶ Chẩn đoán bệnh dựa trên triệu chứng.
- ▶ Phân loại ảnh y khoa.
- ▶ Dự đoán khả năng sống sót của bệnh nhân.

Tình huống thực tế

- ▶ Một ngân hàng nhận rất nhiều hồ sơ vay mỗi ngày.
- ▶ Mỗi hồ sơ có thông tin như mức lương, kinh nghiệm làm việc, lịch sử tín dụng.
- ▶ Cần dự đoán hồ sơ mới có nên được duyệt hay không.



Hình: Ví dụ bài toán duyệt hồ sơ vay

Input

- ▶ Mức lương của người vay.
- ▶ Số năm kinh nghiệm làm việc.
- ▶ Các thông tin tài chính khác.

Output


- ▶ Duyệt hồ sơ vay: class 1.
- ▶ Không duyệt hồ sơ vay: class 0.
- ▶ Đây là bài toán phân loại nhị phân.

Câu hỏi chính

Làm sao để mô hình không chỉ dự đoán **duyet / không duyet**, mà còn cho biết **xác suất được duyet**?

Trực giác

- ▶ Nếu biểu diễn dữ liệu trên mặt phẳng, mỗi hồ sơ là một điểm.
- ▶ Mỗi điểm có thể thuộc nhóm được duyệt hoặc không được duyệt.
- ▶ Ta muốn tìm một đường phân chia hai nhóm dữ liệu này.



Hình: Đường phân chia giữa hai lớp

Vấn đề

- ▶ Linear Regression dự đoán giá trị liên tục.
- ▶ Output có thể nhỏ hơn 0 hoặc lớn hơn 1.
- ▶ Vì vậy output không phù hợp để diễn giải như xác suất.

Điều ta cần

- ▶ Một mô hình cho output nằm trong khoảng 0 đến 1.
- ▶ Output có thể hiểu là xác suất thuộc class 1.
- ▶ Từ xác suất đó, ta đưa ra quyết định phân loại.

Định nghĩa

- ▶ Logistic Regression là thuật toán dùng cho bài toán phân loại.
- ▶ Mô hình dự đoán xác suất một mẫu thuộc về class 1.
- ▶ Sau đó dùng threshold để chuyển xác suất thành nhãn phân loại.

Ví dụ xác suất

- ▶ Hồ sơ vay có 82% khả năng được duyệt.
- ▶ Giao dịch có 90% khả năng là gian lận.
- ▶ Email có 75% khả năng là spam.

Bước 1: Tính điểm số tuyến tính

$$z = w_1x_1 + w_2x_2 + \dots + w_nx_n + b$$

- ▶ x_i : đặc trưng đầu vào.
- ▶ w_i : trọng số của mô hình.
- ▶ b : hệ số bias.

Bước 2: Chuyển thành xác suất


$$\hat{p} = P(y = 1|x) = \sigma(z)$$

- ▶ $\hat{p}$ là xác suất thuộc class 1.
- ▶ $1 - \hat{p}$ là xác suất thuộc class 0.

Công thức

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

- ▶ Input z có thể là bất kỳ số thực nào.
- ▶ Output luôn nằm trong khoảng $(0, 1)$.
- ▶ Vì vậy sigmoid phù hợp để biểu diễn xác suất.



Khi $\hat{p}$ gần 1

- ▶ Mô hình nghiêng về class 1.
- ▶ Ví dụ: hồ sơ có khả năng cao được duyệt.
- ▶ Xác suất càng cao, mô hình càng tự tin.

Khi $\hat{p}$ gần 0

- ▶ Mô hình nghiêng về class 0.
- ▶ Ví dụ: hồ sơ có khả năng cao bị từ chối.
- ▶ Nếu $\hat{p} \approx 0.5$, mô hình chưa chắc chắn.

Loss cho một mẫu dữ liệu

$$L(y, \hat{p}) = -[y \log(\hat{p}) + (1 - y) \log(1 - \hat{p})]$$

Nếu $y = 1$

$$L = -\log(\hat{p})$$

- ▶ Muốn $\hat{p}$ càng gần 1 càng tốt.
- ▶ Nếu dự đoán gần 0, loss sẽ rất lớn.

Nếu $y = 0$

$$L = -\log(1 - \hat{p})$$

- ▶ Muốn $\hat{p}$ càng gần 0 càng tốt.
- ▶ Nếu dự đoán gần 1, loss sẽ rất lớn.

Ý tưởng chính

- ▶ Loss nhỏ khi mô hình dự đoán đúng và tự tin.
- ▶ Loss lớn khi mô hình dự đoán sai nhưng lại quá tự tin.
- ▶ Log Loss phạt dự đoán sai tự tin nặng hơn dự đoán sai nhẹ.

Ví dụ với nhãn thật $y = 1$

$\hat{p}$	$L = -\log(\hat{p})$	Ý nghĩa
0.95	0.05	Đúng, rất tự tin
0.50	0.69	Chưa chắc chắn
0.05	3.00	Sai, rất tự tin

Kết luận

Nếu nhãn thật là class 1, mô hình càng dự đoán $\hat{p}$ gần 1 thì loss càng nhỏ. Ngược lại, nếu dự đoán $\hat{p}$ gần 0 thì loss tăng rất mạnh.

Trung bình loss trên m mẫu

$$J(w, b) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log(\hat{p}^{(i)}) + (1 - y^{(i)}) \log(1 - \hat{p}^{(i)}) \right]$$

Mục tiêu huấn luyện

Tìm các tham số w và b sao cho giá trị $J(w, b)$ nhỏ nhất.

Mục tiêu

- ▶ Bắt đầu từ các trọng số ban đầu.
- ▶ Tính loss của mô hình.
- ▶ Cập nhật trọng số theo hướng làm loss giảm.

Cập nhật tham số

$$w_j := w_j - \alpha \frac{\partial J}{\partial w_j}$$

$$b := b - \alpha \frac{\partial J}{\partial b}$$

- ▶ α : learning rate.
- ▶ Đạo hàm cho biết hướng cần điều chỉnh.

Quy tắc phân loại

$$\hat{y} = \begin{cases} 1, & \text{nếu } \hat{p} \geq t \\ 0, & \text{nếu } \hat{p} < t \end{cases}$$

- ▶ t là threshold.
- ▶ Giá trị phổ biến: $t = 0.5$.

Ví dụ

- ▶ Nếu $\hat{p} = 0.72$ và $t = 0.5$, dự đoán class 1.
- ▶ Nếu $\hat{p} = 0.72$ và $t = 0.8$, dự đoán class 0.
- ▶ Threshold thay đổi quyết định cuối cùng.

Ý nghĩa

- ▶ Decision boundary là ranh giới phân chia hai class.
- ▶ Với threshold 0.5, ranh giới thường tương ứng với $\hat{p} = 0.5$.
- ▶ Các điểm ở hai phía ranh giới được phân vào hai class khác nhau.

Liên hệ với mô hình

$$\hat{p} = \sigma(z)$$

$$\hat{p} = 0.5 \iff z = 0$$

$$w_1x_1 + w_2x_2 + b = 0$$

- ▶ Đây là đường phân chia tuyến tính.

Ứng dụng phổ biến

- ▶ Phân loại email spam.
- ▶ Phát hiện giao dịch gian lận.
- ▶ Dự đoán khối u lành tính hoặc ác tính.

Ứng dụng trong kinh doanh

- ▶ Dự đoán khả năng trả nợ.
- ▶ Dự đoán khách hàng rời bỏ dịch vụ.
- ▶ Dự đoán khoản đầu tư có sinh lời hay không.

Ý tưởng chính

K-Nearest Neighbors (KNN) dự đoán nhãn của một điểm dữ liệu mới dựa trên K điểm dữ liệu gần nó nhất trong tập huấn luyện.

Đầu vào

- ▶ Tập dữ liệu huấn luyện:

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$$

- ▶ Điểm dữ liệu cần dự đoán:

$$\mathbf{x}^*$$

- ▶ Số lượng láng giềng:

$$K$$

Đầu ra

- ▶ Với bài toán phân loại:

$$\hat{y} \in \{C_1, C_2, \dots, C_m\}$$

- ▶ Với bài toán hồi quy:

$$\hat{y} \in \mathbb{R}$$

Quy trình dự đoán

1. Chọn số lượng láng giềng K .
2. Tính khoảng cách từ điểm cần dự đoán $\mathbf{x}^*$ đến tất cả các điểm trong tập huấn luyện.
3. Sắp xếp các điểm theo khoảng cách tăng dần.
4. Chọn K điểm có khoảng cách nhỏ nhất.
5. Tổng hợp kết quả của K láng giềng:
 - ▷ Phân loại: chọn lớp xuất hiện nhiều nhất.
 - ▷ Hồi quy: lấy trung bình giá trị của các láng giềng.

Đặc điểm

KNN không xây dựng một mô hình tham số trong quá trình huấn luyện. Phần lớn phép tính được thực hiện khi dự đoán dữ liệu mới.

Công thức

Với hai điểm dữ liệu có p đặc trưng:

$$\mathbf{x} = (x_1, x_2, \dots, x_p)$$

$$\mathbf{z} = (z_1, z_2, \dots, z_p)$$

khoảng cách Euclidean được xác định bởi:

$$d(\mathbf{x}, \mathbf{z}) = \sqrt{\sum_{j=1}^p (x_j - z_j)^2}$$

Ý nghĩa ký hiệu

- ▶ $d(\mathbf{x}, \mathbf{z})$: khoảng cách giữa hai điểm.
- ▶ p : số lượng đặc trưng.
- ▶ x_i : giá trị đặc trưng thứ i của điểm $\mathbf{x}$.

Ý nghĩa

- ▶ Khoảng cách nhỏ: hai điểm có đặc trưng tương tự nhau.
- ▶ Khoảng cách lớn: hai điểm khác biệt

Giả sử hai điểm dữ liệu:

$$\mathbf{x} = (2, 3), \quad \mathbf{z} = (5, 7)$$

Khoảng cách Euclidean giữa hai điểm là:

$$\begin{aligned} d(\mathbf{x}, \mathbf{z}) &= \sqrt{(2 - 5)^2 + (3 - 7)^2} \\ &= \sqrt{(-3)^2 + (-4)^2} \\ &= \sqrt{9 + 16} \\ &= 5 \end{aligned}$$

Kết luận

Khoảng cách giữa hai điểm $\mathbf{x}$ và $\mathbf{z}$ bằng 5 đơn vị. KNN thực hiện phép tính tương tự với tất cả các điểm trong tập huấn luyện.

Khoảng cách Manhattan

$$d(\mathbf{x}, \mathbf{z}) = \sum_{j=1}^p |x_j - z_j|$$

- ▶ Tổng độ lệch tuyệt đối giữa các đặc trưng.
- ▶ Ít nhạy với giá trị ngoại lệ hơn Euclidean.
- ▶ Phù hợp khi dữ liệu có dạng lưới hoặc đường đi.

Khoảng cách Minkowski

$$d(\mathbf{x}, \mathbf{z}) = \left(\sum_{j=1}^p |x_j - z_j|^q \right)^{\frac{1}{q}}$$

- ▶ $q = 1$: khoảng cách Manhattan.
- ▶ $q = 2$: khoảng cách Euclidean.
- ▶ q : tham số điều chỉnh độ đo khoảng cách.

Lưu ý

Lựa chọn độ đo khoảng cách phụ thuộc vào đặc điểm và phân phối của dữ liệu.

Gọi $\mathcal{N}_K(\mathbf{x}^*)$ là tập hợp K láng giềng gần nhất của điểm $\mathbf{x}^*$.
Nhãn dự đoán được xác định bởi:

$$\hat{y} = \operatorname{argmax}_{c \in \mathcal{C}} \sum_{i \in \mathcal{N}_K(\mathbf{x}^*)} \mathbb{I}(y_i = c)$$

Ý nghĩa ký hiệu

- ▶ $\hat{y}$: nhãn dự đoán.
- ▶ $\mathcal{C}$: tập hợp các lớp.
- ▶ $\mathcal{N}_K(\mathbf{x}^*)$: tập K láng giềng gần nhất.
- ▶ y_i : nhãn của láng giềng thứ i .

Hàm chỉ thị

$$\mathbb{I}(y_i = c) = \begin{cases} 1, & \text{nếu } y_i = c, \\ 0, & \text{nếu } y_i \neq c. \end{cases}$$

Hàm này được sử dụng để đếm số láng giềng thuộc lớp c .

Công thức:

$$\hat{y} = \operatorname{argmax}_{c \in \mathcal{C}} \sum_{i \in \mathcal{N}_K(\mathbf{x}^*)} \mathbb{I}(y_i = c)$$

được hiểu theo ba bước:

Bước 1: Đếm số láng giềng của từng lớp

$$n_c = \sum_{i \in \mathcal{N}_K(\mathbf{x}^*)} \mathbb{I}(y_i = c)$$

Trong đó n_c là số láng giềng thuộc lớp c .

Bước 2: So sánh số phiếu

Thuật toán so sánh số lượng láng giềng của tất cả các lớp.

Bước 3: Chọn lớp có nhiều phiếu nhất

Giả sử chọn:

$$K = 5$$

Năm láng giềng gần nhất có nhãn:

$$\{A, A, B, A, B\}$$

Số phiếu của lớp A

$$n_A = 3$$

Số phiếu của lớp B

$$n_B = 2$$

Do lớp A có số phiếu lớn hơn lớp B:

$$3 > 2$$

nên kết quả dự đoán là:

Trong KNN thông thường, tất cả các láng giềng có mức ảnh hưởng như nhau. Tuy nhiên, các điểm gần hơn thường nên có ảnh hưởng lớn hơn. Trọng số của láng giềng thứ i có thể được xác định bởi:

$$w_i = \frac{1}{d(\mathbf{x}^*, \mathbf{x}_i) + \varepsilon}$$

Nhãn dự đoán trở thành:

$$\hat{y} = \operatorname{argmax}_{c \in \mathcal{C}} \sum_{i \in \mathcal{N}_K(\mathbf{x}^*)} w_i \mathbb{I}(y_i = c)$$

Ý nghĩa

- ▶ w_i : trọng số của láng giềng thứ i .
- ▶ $d(\mathbf{x}^*, \mathbf{x}_i)$: khoảng cách từ điểm cần dự đoán đến láng giềng thứ i .
- ▶ ε : số dương rất nhỏ, giúp tránh phép chia cho 0.
- ▶ Khoảng cách càng nhỏ thì trọng số w_i càng lớn.

Trong bài toán hồi quy, kết quả dự đoán là trung bình giá trị của K láng giềng gần nhất:

$$\hat{y} = \frac{1}{K} \sum_{i \in \mathcal{N}_K(\mathbf{x}^*)} y_i$$

Ý nghĩa ký hiệu

- ▶ $\hat{y}$: giá trị dự đoán.
- ▶ K : số lượng láng giềng.
- ▶ y_i : giá trị đầu ra của láng giềng thứ i .

Ví dụ

Với $K = 3$ và các giá trị:

$\{10, 12, 14\}$

ta có:

$$\hat{y} = \frac{10 + 12 + 14}{3} = 12$$

K quá nhỏ

- ▶ Mô hình nhạy với nhiễu.
- ▶ Biên phân chia phức tạp.
- ▶ Dễ xảy ra overfitting.
- ▶ Phương sai cao.

K quá lớn

- ▶ Mô hình bỏ qua cấu trúc cục bộ.
- ▶ Biên phân chia quá đơn giản.
- ▶ Dễ xảy ra underfitting.
- ▶ Độ chệch cao.

Cách lựa chọn K

- ▶ Thử nhiều giá trị K khác nhau.
- ▶ Đánh giá bằng tập validation hoặc cross-validation.
- ▶ Chọn K cho sai số dự đoán thấp nhất.
- ▶ Trong phân loại nhị phân, thường chọn K lẻ để hạn chế hòa phiếu.

Giả sử:

n = số lượng mẫu huấn luyện

p = số lượng đặc trưng

Giai đoạn huấn luyện

- ▶ KNN chủ yếu lưu trữ dữ liệu.
- ▶ Không cần tối ưu hàm mất mát.
- ▶ Chi phí huấn luyện tương đối thấp.

$$T_{\text{train}} \approx O(1)$$

Giai đoạn dự đoán

Phải tính khoảng cách đến n điểm, mỗi điểm có p đặc trưng:

$$T_{\text{predict}} = O(np)$$

Do đó KNN có thể chậm khi dữ liệu lớn.

Ưu điểm

- ▶ Dễ hiểu và dễ triển khai.
- ▶ Không cần giả định phân phối dữ liệu.
- ▶ Áp dụng được cho cả phân loại và hồi quy.
- ▶ Có thể mô hình hóa biên phân chia phi tuyến.
- ▶ Không cần quá trình huấn luyện phức tạp.

Hạn chế

- ▶ Dự đoán chậm khi dữ liệu lớn.
- ▶ Nhạy với thang đo của đặc trưng.
- ▶ Nhạy với nhiễu và giá trị ngoại lệ.
- ▶ Hiệu quả giảm khi số chiều tăng.
- ▶ Cần lựa chọn K và độ đo khoảng cách phù hợp.

Ứng dụng phổ biến

- ▶ Nhận dạng chữ viết tay.
- ▶ Phân loại hình ảnh.
- ▶ Phân loại văn bản.
- ▶ Phát hiện giao dịch bất thường.
- ▶ Hỗ trợ chẩn đoán bệnh.

Ứng dụng trong kinh doanh

- ▶ Phân nhóm khách hàng.
- ▶ Dự đoán khả năng rời bỏ dịch vụ.
- ▶ Gợi ý sản phẩm tương tự.
- ▶ Dự đoán giá dựa trên các sản phẩm gần giống.
- ▶ Đánh giá mức độ rủi ro của khách hàng.

Mục tiêu đánh giá

- ▶ Kiểm tra mô hình dự đoán đúng hay sai trên dữ liệu chưa thấy.
- ▶ So sánh hiệu quả giữa Logistic Regression và KNN.
- ▶ Chọn mô hình phù hợp với mục tiêu bài toán.

Quy trình cơ bản

- ▶ Chia dữ liệu thành train set và test set.
- ▶ Huấn luyện model trên train set.
- ▶ Dự đoán trên test set.
- ▶ Tính các chỉ số đánh giá.

Lưu ý

Logistic Regression và KNN có thể dùng chung các metric như Accuracy, Precision, Recall, F1-score và Confusion Matrix.

Confusion Matrix

	Dự đoán 1	Dự đoán 0
Thực tế 1	TP	FN
Thực tế 0	FP	TN

- ▶ TP: dự đoán đúng class positive.
- ▶ TN: dự đoán đúng class negative.
- ▶ FP: dự đoán nhầm thành positive.
- ▶ FN: bỏ sót class positive.

Các chỉ số đánh giá

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

- [1] Pham Van Chung. (2020, September 18). *Logistic Regression – Bài toán cơ bản trong Machine Learning*. Viblo.
<https://viblo.asia/p/logistic-regression-bai-toan-co-ban-trong-machine-learning-924lJ4rzKPM>
- [2] Machine Learning Cơ Bản. (2017, January 27). *Bài 10: Logistic Regression*. Machine Learning Cơ Bản. <https://machinelearningcoban.com/2017/01/27/logisticregression/>

Thank You

Acknowledgements

The authors gratefully acknowledge [Funding agency / Collaborators / Lab / Advisor names] for their support and guidance.