

Dimensionality Reduction

Phan Quoc Dai Son^{*a}

^a Machine Learning & IoT Lab, HCMUT

*Email: sonphan0202@gmail.com

Machine Learning & IoT Lab (ML IoT)
Ho Chi Minh City University of Technology (HCMUT)

1. Tổng quan về giảm chiều dữ liệu và lời nguyên số chiều
2. Nền tảng toán học: eigenvalue, eigenvector và phân rã ma trận
3. Singular Value Decomposition: $A = U\Sigma V^T$
4. Truncated SVD, xấp xỉ rank- k và cách lựa chọn k
5. Ứng dụng SVD trong nén ảnh, NLP và hệ thống gợi ý
6. Thực hành, tổng kết, thảo luận và hỏi đáp

Contact Information

Address: 403.1 BK.B6, HCMUT
Campus 2

Email:
sonphan0202@gmail.com
mlandiotlab@gmail.com

Website: mliotlab.com

Facebook:
facebook.com/hcmut.ml.iot.lab

YouTube: youtube.com/@mliotlab

Phần 1

Lý do cần giảm chiều dữ liệu

- ▶ Ảnh 28×28 có 784 features
- ▶ Ảnh RGB 224×224 có:
$$224 \times 224 \times 3 = 150,528$$
- ▶ Văn bản có thể có hàng chục nghìn từ
- ▶ Dữ liệu gene có thể có hàng chục nghìn gene

Câu hỏi

Có phải càng nhiều feature thì mô hình càng tốt?

Vấn đề

Nhiều feature hơn không đồng nghĩa với nhiều thông tin hữu ích hơn.

Giả sử mỗi chiều được chia thành 10 khoảng:

Số chiều	Số vùng cần biểu diễn
1	10
2	$10^2 = 100$
3	$10^3 = 1,000$
10	10^{10}
100	10^{100}

Hệ quả

Khi số chiều tăng, không gian tăng rất nhanh và dữ liệu trở nên thưa thớt.



Trong không gian nhiều chiều:

- ▶ Các điểm dữ liệu trở nên rất thưa.
- ▶ Khoảng cách giữa các điểm ngày càng ít khác biệt.
- ▶ Khái niệm “điểm gần nhất” trở nên kém rõ ràng.
- ▶ Mô hình cần nhiều dữ liệu hơn để học được cấu trúc thật.

KNN

Khó xác định hàng xóm gần.

K-Means

Khoảng cách đến centroid kém phân biệt.

DBSCAN

Khó chọn bán kính lân cận.

Hiệu quả tính toán

- ▶ Giảm thời gian huấn luyện
- ▶ Giảm bộ nhớ lưu trữ
- ▶ Tăng tốc xử lý dữ liệu

Chất lượng mô hình

- ▶ Giảm nhiễu
- ▶ Giảm overfitting
- ▶ Giữ cấu trúc quan trọng

Trực quan hóa

Đưa dữ liệu nhiều chiều về 2D hoặc 3D để quan sát.

Biểu diễn dữ liệu

Tìm các yếu tố ẩn giải thích phần lớn biến thiên trong dữ liệu.

Feature Selection

Chọn một tập con của feature ban đầu.

$$[x_1, x_2, x_3, x_4] \rightarrow [x_1, x_3]$$

- ▶ Giữ nguyên ý nghĩa feature
- ▶ Dễ diễn giải
- ▶ Ví dụ: LASSO, SelectKBest

Feature Extraction

Tạo feature mới từ feature ban đầu.

$$[x_1, x_2, x_3, x_4] \rightarrow [z_1, z_2]$$

- ▶ Tạo biểu diễn mới
- ▶ Có thể khó diễn giải hơn
- ▶ Ví dụ: PCA, SVD, Autoencoder

SVD tìm các hướng quan trọng nhất trong một ma trận dữ liệu:

$$A = U\Sigma V^T$$

- ▶ Các singular value cho biết mức độ quan trọng của từng hướng.
- ▶ Các hướng quan trọng nhất thường giữ phần lớn cấu trúc dữ liệu.
- ▶ Truncated SVD chỉ giữ lại k thành phần lớn nhất.
- ▶ Nhờ đó, dữ liệu được biểu diễn trong không gian có số chiều nhỏ hơn.

Ý tưởng cốt lõi

Giảm chiều bằng SVD nghĩa là giữ lại phần cấu trúc mạnh nhất và bỏ bớt phần đóng góp yếu.

Phần 2

Nền tảng toán học của SVD



Cho ma trận:

$$A \in \mathbb{R}^{m \times n}$$

và vector đầu vào:

$$x \in \mathbb{R}^n$$

Khi đó:

$$y = Ax$$

biểu diễn một ánh xạ tuyến tính:

$$A : \mathbb{R}^n \rightarrow \mathbb{R}^m$$

Ý nghĩa

Ma trận có thể làm vector bị xoay, co giãn, phản xạ hoặc thay đổi số chiều.

Một vector khác không v được gọi là eigenvector của A nếu:

$$Av = \lambda v$$

Trong đó:

- ▶ v là eigenvector.
- ▶ λ là eigenvalue.

Ý nghĩa hình học

Sau khi nhân với A , eigenvector không đổi phương, chỉ thay đổi độ dài hoặc chiều.

Eigendecomposition thường có dạng:

$$A = PDP^{-1}$$

Tuy nhiên:

- ▶ Thường áp dụng trực tiếp cho ma trận vuông.
- ▶ Không phải ma trận nào cũng chéo hóa được.
- ▶ Eigenvector không nhất thiết trực giao.
- ▶ Không thuận tiện với dữ liệu dạng $m \times n$ khi $m \neq n$.

Nhu cầu

Cần một phép phân rã tổng quát hơn, ổn định hơn và áp dụng được cho mọi ma trận.

Thay vì xử lý trực tiếp một ma trận phức tạp A , ta biểu diễn nó thành tích của các ma trận đơn giản hơn.

Một số dạng phân rã quen thuộc:

$$A = PDP^{-1}$$

$$A = LU$$

$$A = QR$$

SVD cũng là một dạng phân rã ma trận:

$$A = U\Sigma V^T$$

Điểm mạnh

SVD tồn tại với mọi ma trận thực, kể cả ma trận không vuông.

Với mọi ma trận:

$$A \in \mathbb{R}^{m \times n}$$

ta có thể phân rã:

$$A = U\Sigma V^T$$

Trong đó:

- ▶ $U \in \mathbb{R}^{m \times m}$ là ma trận trực giao.
- ▶ $\Sigma \in \mathbb{R}^{m \times n}$ là ma trận đường chéo mở rộng.
- ▶ $V \in \mathbb{R}^{n \times n}$ là ma trận trực giao.

$$U^T U = I_m, \quad V^T V = I_n$$

Thành phần	Kích thước	Ý nghĩa
U	$m \times m$	Left singular vectors
Σ	$m \times n$	Singular values
V	$n \times n$	Right singular vectors

Các singular value nằm trên đường chéo của Σ :

$$\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$$

với:

$$r = \text{rank}(A)$$

V^T

Xoay hoặc phản xạ không gian đầu vào.

Σ

Co giãn theo các trục chính. Singular value càng lớn, mức độ co giãn càng mạnh.

U

Xoay hoặc phản xạ sang không gian đầu ra.

Với:

$$y = Ax = U\Sigma V^T x$$

ta đọc phép biến đổi từ phải sang trái:

$$V^T \rightarrow \Sigma \rightarrow U$$

Giả sử:

$$A \in \mathbb{R}^{4 \times 3}$$

Khi đó:

$$U \in \mathbb{R}^{4 \times 4}$$

$$\Sigma \in \mathbb{R}^{4 \times 3}$$

$$V^T \in \mathbb{R}^{3 \times 3}$$

Kiểm tra phép nhân:

$$\underbrace{(4 \times 4)}_U \underbrace{(4 \times 3)}_\Sigma \underbrace{(3 \times 3)}_{V^T} = \underbrace{(4 \times 3)}_A$$

Xét:

$$y = Ax = U\Sigma V^T x$$

Quá trình biến đổi:

$$x \xrightarrow{V^T} V^T x \xrightarrow{\Sigma} \Sigma V^T x \xrightarrow{U} U \Sigma V^T x$$

Xoay đầu vào $\rightarrow$ Co giãn $\rightarrow$ Xoay đầu ra

Thực quan

Một hình tròn có thể bị biến đổi thành hình ellipse thông qua chuỗi xoay và co giãn.

Từ:

$$A = U\Sigma V^T$$

ta xét:

$$A^T A$$

Thay SVD vào:

$$\begin{aligned} A^T A &= (U\Sigma V^T)^T (U\Sigma V^T) \\ &= V\Sigma^T U^T U \Sigma V^T \\ &= V\Sigma^T \Sigma V^T \end{aligned}$$

vì:

$$U^T U = I$$

Ta có:

$$A^T A = V \Sigma^T \Sigma V^T$$

Đây là eigendecomposition của $A^T A$.

Suy ra:

- ▶ Các cột của V là eigenvector của $A^T A$.
- ▶ Các eigenvalue của $A^T A$ là σ_i^2 .
- ▶ Singular value là căn bậc hai của eigenvalue:

$$\sigma_i = \sqrt{\lambda_i}$$

Tương tự, xét:

$$AA^T$$

Ta có:

$$AA^T = U\Sigma\Sigma^T U^T$$

Suy ra:

- ▶ Các cột của U là eigenvector của AA^T .
- ▶ Các eigenvalue của AA^T cũng là σ_i^2 .
- ▶ U mô tả các hướng chính trong không gian đầu ra.

Tóm tắt

V đến từ $A^T A$, còn U đến từ AA^T .

Xét ma trận:

$$A = \begin{bmatrix} 3 & 0 \\ 4 & 0 \end{bmatrix}$$

Ta cần tìm ba ma trận:

$$A = U\Sigma V^T$$

Quy trình:

$$A^T A \rightarrow \lambda_i, v_i \rightarrow \sigma_i \rightarrow u_i$$

Các bước chính

1. Tính $A^T A$.
2. Tìm eigenvalue và eigenvector để xây dựng V .
3. Tính singular value để xây dựng Σ .
4. Tính U từ $u_i = Av_i / \sigma_i$.

Ta có:

$$A^T = \begin{bmatrix} 3 & 4 \\ 0 & 0 \end{bmatrix}$$

Do đó:

$$\begin{aligned} A^T A &= \begin{bmatrix} 3 & 4 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 3 & 0 \\ 4 & 0 \end{bmatrix} \\ &= \begin{bmatrix} 25 & 0 \\ 0 & 0 \end{bmatrix} \end{aligned}$$

Tìm eigenvalue bằng phương trình:

$$\det(A^T A - \lambda I) = 0$$

$$(25 - \lambda)(-\lambda) = 0$$

Singular value là căn bậc hai của eigenvalue:

$$\sigma_1 = \sqrt{25} = 5, \quad \sigma_2 = \sqrt{0} = 0$$

Do đó:

$$\Sigma = \begin{bmatrix} 5 & 0 \\ 0 & 0 \end{bmatrix}$$

Các eigenvector đơn vị của $A^T A$ là:

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

Vì vậy:

$$V = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

Với $\sigma_1 \neq 0$, ta dùng:

$$u_1 = \frac{Av_1}{\sigma_1}$$

Ta có:

$$Av_1 = \begin{bmatrix} 3 \\ 4 \end{bmatrix}$$

Do đó:

$$u_1 = \frac{1}{5} \begin{bmatrix} 3 \\ 4 \end{bmatrix} = \begin{bmatrix} \frac{3}{5} \\ \frac{4}{5} \end{bmatrix}$$

Chọn u_2 là vector đơn vị vuông góc với u_1 :

$$u_2 = \begin{bmatrix} -\frac{4}{5} \\ \frac{3}{5} \end{bmatrix}$$

Ta thu được:

$$A = U\Sigma V^T$$

với:

$$U = \begin{bmatrix} \frac{3}{5} & -\frac{4}{5} \\ \frac{4}{5} & \frac{3}{5} \end{bmatrix}$$

$$\Sigma = \begin{bmatrix} 5 & 0 \\ 0 & 0 \end{bmatrix}, \quad V^T = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

Kiểm tra:

$$U\Sigma V^T = \begin{bmatrix} 3 & 0 \\ 4 & 0 \end{bmatrix} = A$$

Nhận xét

Mã trận A có rank bằng 1, nên chỉ có một singular value khác 0.

Các singular value:

$$\sigma_1, \sigma_2, \dots, \sigma_r$$

cho biết mức độ đóng góp của từng thành phần trong ma trận.

- ▶ σ_i lớn: thành phần đó mang nhiều cấu trúc quan trọng.
- ▶ σ_i nhỏ: thành phần đó đóng góp ít hơn.
- ▶ Nếu nhiều singular value nhỏ, ma trận có thể được xấp xỉ bằng rank thấp.

Kết nối sang Truncated SVD

Giảm chiều bằng SVD bắt đầu từ ý tưởng: giữ singular value lớn, bỏ singular value nhỏ.

Phần 3

Truncated SVD và giảm chiều dữ liệu

Full SVD

$$A = U\Sigma V^T$$

với:

$$A \in \mathbb{R}^{m \times n}$$

Full SVD giữ đầy đủ kích thước của U và V .

Compact SVD

Nếu:

$$r = \text{rank}(A)$$

thì compact SVD là:

$$A = U_r \Sigma_r V_r^T$$

Chỉ giữ các singular value khác 0.

Điểm quan trọng

Compact SVD vẫn tái tạo chính xác ma trận A .

Compact SVD:

$$A = U_r \Sigma_r V_r^T, \quad r = \text{rank}(A)$$

Ma trận	Kích thước	Ý nghĩa
U_r	$m \times r$	Left singular vectors
Σ_r	$r \times r$	Singular values khác 0
V_r	$n \times r$	Right singular vectors
V_r^T	$r \times n$	Chuyển vị của V_r

$$\underbrace{(m \times r)}_{U_r} \underbrace{(r \times r)}_{\Sigma_r} \underbrace{(r \times n)}_{V_r^T} = \underbrace{(m \times n)}_A$$

Truncated SVD chọn $k < r$ và chỉ giữ k singular value lớn nhất:

$$A_k = U_k \Sigma_k V_k^T$$

Ma trận	Kích thước
U_k	$m \times k$
Σ_k	$k \times k$
V_k	$n \times k$
V_k^T	$k \times n$

Compact SVD

$$A = U_r \Sigma_r V_r^T$$

Tái tạo chính xác A .

Truncated SVD

$$A \approx A_k$$

Tạo xấp xỉ rank- k .



Dạng	Công thức	Thành phần	Kết quả
Full SVD	$A = U\Sigma V^T$	đầy đủ	chính xác
Compact SVD	$A = U_r \Sigma_r V_r^T$	r	chính xác
Truncated SVD	$A_k = U_k \Sigma_k V_k^T$	$k < r$	xấp xỉ

Mục tiêu

Thay ma trận gốc bằng một biểu diễn đơn giản hơn nhưng vẫn giữ phần thông tin quan trọng nhất.



SVD có thể viết thành:

$$A = \sum_{i=1}^r \sigma_i u_i v_i^T$$

Tức là:

$$A = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \cdots + \sigma_r u_r v_r^T$$

Ý nghĩa

Mỗi thành phần $\sigma_i u_i v_i^T$ là một ma trận rank-1 đóng góp vào cấu trúc của A .



Truncated SVD chỉ giữ k thành phần đầu tiên:

$$A_k = \sum_{i=1}^k \sigma_i u_i v_i^T$$

hay:

$$A_k = \sigma_1 u_1 v_1^T + \cdots + \sigma_k u_k v_k^T$$

Ý tưởng

Các singular value lớn nhất được giữ lại vì chúng đóng góp nhiều nhất vào ma trận gốc.

Ma trận A_k có rank không vượt quá k :

$$\text{rank}(A_k) \leq k$$

Ma trận gốc

$$A \in \mathbb{R}^{m \times n}$$

Có thể lớn, nhiều và khó xử lý trực tiếp.

Ma trận xấp xỉ

$$A_k = U_k \Sigma_k V_k^T$$

Giữ cấu trúc chính với rank thấp.

Kết luận

Nếu k nhỏ hơn nhiều so với r , dữ liệu được biểu diễn gọn hơn đáng kể.

Trong tất cả các ma trận B có rank không vượt quá k , A_k là ma trận gần A nhất theo chuẩn Frobenius:

$$A_k = \arg \min_{\text{rank}(B) \leq k} \|A - B\|_F$$

Sai số xấp xỉ:

$$\|A - A_k\|_F^2 = \sum_{i=k+1}^r \sigma_i^2$$

Ý nghĩa

Bỏ các singular value nhỏ nhất tạo ra sai số nhỏ nhất cho xấp xỉ rank- k .

Tổng năng lượng của ma trận:

$$\sum_{i=1}^r \sigma_i^2$$

Năng lượng giữ lại khi chọn k thành phần:

$$E(k) = \frac{\sum_{i=1}^k \sigma_i^2}{\sum_{i=1}^r \sigma_i^2}$$

Ngưỡng phổ biến

$$E(k) \geq 90\%$$

Ngưỡng chặt hơn

$$E(k) \geq 95\%$$

1. **Cumulative energy**

Chọn k sao cho giữ được 90%–95% năng lượng.

2. **Scree plot**

Vẽ các singular value và chọn điểm “khuỷu tay”.

3. **Validation performance**

Thử nhiều giá trị k và chọn giá trị có hiệu năng tốt nhất trên validation set.

Lưu ý

Giữ nhiều năng lượng hơn không phải lúc nào cũng giúp mô hình tốt hơn.



Giả sử ma trận dữ liệu:

$$X \in \mathbb{R}^{N \times d}$$

trong đó N là số mẫu, d là số feature ban đầu.

Sau Truncated SVD:

$$X \approx U_k \Sigma_k V_k^T$$

Biểu diễn giảm chiều của dữ liệu:

$$Z = U_k \Sigma_k, \quad Z \in \mathbb{R}^{N \times k}$$

Kết quả

Mỗi mẫu từ d feature ban đầu được biểu diễn bằng k feature mới, với $k < d$.

Cho dữ liệu đã được center:

$$X_c = X - \bar{X}$$

Thực hiện SVD:

$$X_c = U\Sigma V^T$$

Trong PCA:

- ▶ Các cột của V là principal directions.
- ▶ Dữ liệu sau khi chiếu xuống k chiều là:

$$Z = X_c V_k$$

Do đó:

$$Z = X_c V_k = U_k \Sigma_k$$

Tiêu chí	SVD	PCA
Bản chất	Phân rã ma trận	Giảm chiều thống kê
Đầu vào	Ma trận bất kỳ	Ma trận dữ liệu
Center dữ liệu	Không bắt buộc	Thường bắt buộc
Kết quả	U, Σ, V	Principal components
Vai trò	Tổng quát hơn	Ứng dụng cụ thể của SVD

Kết luận

PCA có thể được tính bằng SVD trên dữ liệu đã được center.



Giả sử có 4 người dùng và 4 bộ phim:

	Phim 1	Phim 2	Phim 3	Phim 4
User 1	5	4	1	1
User 2	4	?	1	1
User 3	1	1	5	4
User 4	1	1	4	5

Trong đó:

- ▶ Điểm đánh giá nằm trong khoảng từ 1 đến 5.
- ▶ User 2 chưa đánh giá Phim 2.
- ▶ Mục tiêu là dự đoán điểm của User 2 cho Phim 2.

Quan sát

User 1 và User 2 có hành vi khá giống nhau, nên có khả năng User 2 cũng thích Phim 2.

Để minh họa phép tính SVD, giá trị chưa biết được tạm thời thay bằng 0:

$$R = \begin{bmatrix} 5 & 4 & 1 & 1 \\ 4 & 0 & 1 & 1 \\ 1 & 1 & 5 & 4 \\ 1 & 1 & 4 & 5 \end{bmatrix}$$

Trong đó:

$$R \in \mathbb{R}^{4 \times 4}$$

Mỗi hàng biểu diễn một người dùng, còn mỗi cột biểu diễn một bộ phim.

Mục tiêu

Tìm một ma trận xấp xỉ hạng thấp $\hat{R}$ để phát hiện các cấu trúc sở thích ẩn giữa người dùng và phim.

Ta phân rã ma trận đánh giá:

$$R = U\Sigma V^T$$

Các singular value của R xấp xỉ:

$$\sigma_1 = 10.245, \quad \sigma_2 = 6.000,$$

$$\sigma_3 = 2.245, \quad \sigma_4 = 1.000$$

Do đó:

$$\Sigma = \begin{bmatrix} 10.245 & 0 & 0 & 0 \\ 0 & 6.000 & 0 & 0 \\ 0 & 0 & 2.245 & 0 \\ 0 & 0 & 0 & 1.000 \end{bmatrix}$$

Nhận xét



Ta chọn:

$$k = 2$$

và chỉ giữ hai singular value lớn nhất:

$$\Sigma_2 = \begin{bmatrix} 10.245 & 0 \\ 0 & 6.000 \end{bmatrix}$$

Khi đó, ma trận xấp xỉ hạng 2 là:

$$\hat{R} = U_2 \Sigma_2 V_2^T$$

với:

$$U_2 \in \mathbb{R}^{4 \times 2}, \quad \Sigma_2 \in \mathbb{R}^{2 \times 2}, \quad V_2^T \in \mathbb{R}^{2 \times 4}$$

Ý nghĩa

Mỗi người dùng và mỗi bộ phim được biểu diễn bằng hai đặc trưng ẩn thay vì bốn giá trị ban đầu

Trong không gian hai chiều:

$$U_2$$

biểu diễn sở thích ẩn của người dùng, còn:

$$V_2$$

biểu diễn đặc trưng ẩn của các bộ phim.

Hai đặc trưng này có thể được diễn giải gần đúng như:

- ▶ Đặc trưng ẩn 1: mức độ yêu thích nhóm Phim 1-2.
- ▶ Đặc trưng ẩn 2: mức độ yêu thích nhóm Phim 3-4.

Điểm quan trọng

Hệ thống không cần được cung cấp thể loại phim; SVD tự phát hiện các nhóm sở thích từ dữ liệu đánh giá.

Sau khi giữ lại hai thành phần lớn nhất, ta thu được:

$$\hat{R} = U_2 \Sigma_2 V_2^T$$

$$\hat{R} \approx \begin{bmatrix} 5.51 & 3.06 & 1.04 & 1.04 \\ 3.06 & \boxed{1.73} & 0.93 & 0.93 \\ 1.04 & 0.93 & 4.50 & 4.50 \\ 1.04 & 0.93 & 4.50 & 4.50 \end{bmatrix}$$

Giá trị tại hàng 2, cột 2 là:

$$\hat{r}_{2,2} \approx 1.73$$

Đây là điểm dự đoán của User 2 cho Phim 2 theo mô hình xấp xỉ hạng 2.

Điểm dự đoán cho User 2:

	Phim 1	Phim 2	Phim 3	Phim 4
Điểm dự đoán	3.06	1.73	0.93	0.93

User 2 đã đánh giá Phim 1, Phim 3 và Phim 4.
Phim chưa đánh giá là:

Phim 2

với điểm dự đoán:

$$\hat{r}_{2,2} = 1.73$$

Quy tắc đề xuất

Hệ thống xếp hạng các phim chưa xem theo điểm dự đoán và đề xuất các phim có điểm cao nhất.

Ma trận user-item



$$R = U\Sigma V^T$$



Giữ k singular value lớn nhất



$$\hat{R} = U_k \Sigma_k V_k^T$$

Trong ví dụ minh họa, giá trị chưa đánh giá được tạm thay bằng 0 để có thể thực hiện SVD trực tiếp.

Tuy nhiên, trong hệ thống thực tế:

- ▶ Giá trị thiếu không đồng nghĩa với người dùng không thích sản phẩm.
- ▶ Mô hình chỉ nên tính sai số trên các rating đã quan sát.
- ▶ Thường cần bổ sung user bias và item bias.
- ▶ Cần regularization để hạn chế overfitting.

Mô hình thường dùng

Matrix Factorization tối ưu trực tiếp các rating đã biết thường phù hợp hơn việc thay toàn bộ giá trị thiếu bằng 0.

- [1] Vu Huu Tiep. (2017, June 7). *Bài 26: Singular Value Decomposition*. Machine Learning Cơ Bản. <https://machinelearningcoban.com/2017/06/07/svd/>

Thank You

Acknowledgements

The authors gratefully acknowledge [Funding agency / Collaborators / Lab / Advisor names] for their support and guidance.