



# Support Vector Machines

Duy-Tan Nguyen<sup>\*</sup>

HCMUT EE Machine Learning & IoT Lab,  
Ho Chi Minh City University of Technology (HCMUT)

Bài trình bày dựa trên Day 11: Support Vector Machines

---

Machine Learning & IoT Lab (ML IoT)  
Ho Chi Minh City University of Technology (HCMUT)

1. Tổng quan
2. Soft-margin Support Vector Machine
3. Kernel Support Vector Machine (đọc thêm)
4. Multi-class Support Vector Machine (đọc thêm)

## I. Tổng quan

## Khoảng cách từ một điểm đến hyperplane

Khoảng cách từ điểm/vector  $x_0$  đến hyperplane được xác định bởi

$$w^T x + b = 0$$


được tính bởi

$$d(x_0, H) = \frac{|w^T x_0 + b|}{\|w\|_2}.$$

trong đó



$$\|w\|_2 = \sqrt{\sum_{i=1}^d w_i^2},$$

và  $d$  là số chiều của không gian.



## Mối liên hệ với PLA

- ▶ SVM xuất phát từ cùng bài toán binary classification như Perceptron Learning Algorithm.
- ▶ PLA tìm một separating hyperplane khi dữ liệu linearly separable.
- ▶ SVM tiến xa hơn: không chỉ tìm một hyperplane hợp lệ mà còn tìm hyperplane có margin lớn nhất.



## Tài liệu tham khảo

[machinelearningcoban.com/2017/04/09/smv/](http://machinelearningcoban.com/2017/04/09/smv/)

## Training set có label

Giả sử một training set gồm  $N$  cặp dữ liệu có label:

$$(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N).$$

trong đó mỗi input vector  $x_i \in \mathbb{R}^d$  và label tương ứng thỏa mãn

$$y_i \in \{+1, -1\}.$$

Ở đây,  $d$  là số chiều của dữ liệu và  $N$  là số samples.

## Signed distance

Signed distance từ  $x_n$  đến hyperplane là

$$\frac{y_n(w^T x_n + b)}{\|w\|_2}.$$

## Margin

Margin được định nghĩa là khoảng cách nhỏ nhất từ samples của hai lớp đến separating hyperplane:

$$\text{margin} = \min_n \frac{y_n (w^T x_n + b)}{\|w\|_2}.$$

## Mục tiêu optimization

Bài toán SVM chọn  $(w, b)$  sao cho margin được tối đa hóa:

$$(w, b) = \arg \max_{w, b} \frac{1}{\|w\|_2} \min_n y_n (w^T x_n + b).$$

## Thách thức

Dạng optimization trực tiếp này khó giải.

## Normalization

Ta scale  $w$  và  $b$  sao cho

$$y_n(w^T x_n + b) \geq 1, \quad n = 1, \dots, N.$$


Khi đó margin trở thành  $1/\|w\|_2$ .

## Bài toán minimization tương đương

$$(w, b) = \arg \min_{w, b} \frac{1}{2} \|w\|_2^2$$

với ràng buộc

$$1 - y_n(w^T x_n + b) \leq 0, \quad n = 1, \dots, N.$$





## Phân loại một điểm mới

Sau khi tìm được  $(w, b)$ , label của điểm mới  $x$  là

$$\text{class}(x) = \text{sgn}(w^T x + b) = \begin{cases} +1, & w^T x + b \geq 0, \\ -1, & \text{ngược lại.} \end{cases}$$

## Thảo luận

Tại sao dùng  $y_n(w^T x_n + b)$  thay vì  $|w^T x_n + b|$ ?

- ▶  $y_n$  chuyển hai lớp về cùng một điều kiện classification đúng.
- ▶ Nếu sample được classification đúng thì  $y_n(w^T x_n + b) > 0$ .
- ▶ Nếu sample bị misclassified thì đại lượng này âm.

## Kết quả cổ điển

Cho  $U$  là một tập mở trong  $\mathbb{R}^n$ . Giả sử ta optimize hàm trơn  $f : U \rightarrow \mathbb{R}$  với ràng buộc  $g(x) = c$ . Nếu  $f$  đạt local maximum/minimum tại điểm  $a$  và  $\nabla g(a) \neq 0$  thì

$$\nabla f(a) = \lambda \nabla g(a).$$

Scalar  $\lambda$  được gọi là Lagrange multiplier.

## Động lực trong SVM

SVM có các inequality constraints, vì vậy ta sử dụng Lagrangian duality và KKT conditions.

Don Shimamoto, Multivariable Calculus, Swarthmore College.

## Primal form

Xét bài toán optimization tổng quát:

$$\mathbf{x}^* = \arg \min_{\mathbf{x}} f_0(\mathbf{x})$$

với các ràng buộc

$$f_i(\mathbf{x}) \leq 0, \quad i = 1, 2, \dots, m,$$

$$h_j(\mathbf{x}) = 0, \quad j = 1, 2, \dots, p.$$

## Miền xác định

$$D = \left( \bigcap_{i=1}^m \text{dom } f_i \right) \cap \left( \bigcap_{j=1}^p \text{dom } h_j \right).$$

Understanding Duality and Lagrangians in Optimization, MLDemystified.

## Lagrangian

Với bài toán constrained optimization tổng quát, định nghĩa

$$L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\nu}) = f_0(\mathbf{x}) + \sum_{i=1}^m \lambda_i f_i(\mathbf{x}) + \sum_{j=1}^p \nu_j h_j(\mathbf{x}).$$

- ▶ Lagrange cổ điển giúp tìm stationary points.
- ▶ Phương pháp này không cho biết trực tiếp một điểm có phải global min/max hay không.
- ▶ Duality và các optimality conditions bổ sung giúp đặc trưng nghiệm tối ưu.

## Góc nhìn primal và dual

Trong mathematical optimization, một bài toán có thể được nhìn từ hai góc độ: primal problem và dual problem.

## Lagrangian dual function

$$\begin{aligned} g(\lambda, \nu) &= \inf_{x \in D} L(x, \lambda, \nu) \\ &= \inf_{x \in D} \left( f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{j=1}^p \nu_j h_j(x) \right). \end{aligned}$$

- ▶ Với các multipliers  $(\lambda, \nu)$  cố định, minimize Lagrangian theo  $x$ .
- ▶ Giá trị thu được trở thành  $g(\lambda, \nu)$ .

## Slater's condition cho Hard-margin SVM

Nếu tồn tại  $(w, b)$  sao cho

$$1 - y_n(w^T x_n + b) < 0, \quad n = 1, \dots, N,$$

thì strong duality đúng.

## SVM Lagrangian

$$\mathcal{L}(w, b, \lambda) = \frac{1}{2} \|w\|_2^2 + \sum_{n=1}^N \lambda_n (1 - y_n(w^T x_n + b)),$$

với  $\lambda = [\lambda_1, \dots, \lambda_N]$  và  $\lambda_n \geq 0$ .

## Dual function

Lagrange dual function là

$$g(\lambda) = \min_{w, b} \mathcal{L}(w, b, \lambda), \quad \lambda \succeq 0.$$

Lagrange dual function là hàm concave.

## Dual problem

Kết hợp dual function và các constraints, ta có

$$\lambda^* = \arg \max_{\lambda} g(\lambda)$$

với các ràng buộc

$$\lambda \succeq 0, \quad \sum_{n=1}^N \lambda_n y_n = 0.$$

## Karush–Kuhn–Tucker conditions

KKT conditions tổng quát hóa Lagrange multipliers và đưa ra các điều kiện cần cho optimality trong hệ có equality và inequality constraints.

- ▶ Stationarity: tồn tại nghiệm tối ưu của hàm Lagrange.
- ▶ Primal feasibility: nghiệm thỏa các constraints của bài toán gốc.
- ▶ Dual feasibility: nghiệm thỏa các constraints của dual problem.
- ▶ Complementary slackness: với mỗi inequality, constraint đang active hoặc dual coefficient bằng không.

Adam Rumpf, Introduction to the Karush-Kuhn-Tucker Conditions.



## KKT system

- ▶ Stationarity:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{w}} = 0, \quad \frac{\partial \mathcal{L}}{\partial \mathbf{b}} = 0.$$

- ▶ Primal feasibility: các Slater/primal constraints được thỏa mãn.
- ▶ Dual feasibility:  $\lambda \succeq 0$ .
- ▶ Complementary slackness:

$$\lambda_n \left( 1 - y_n (\mathbf{w}^T \mathbf{x}_n + \mathbf{b}) \right) = 0.$$

## Ý chính

Nếu một convex problem thỏa Slater's criterion thì strong duality đúng; khi đó giải hệ KKT cũng giải được bài toán gốc.

## Câu hỏi thảo luận


1. Tại sao mô hình được gọi là Support Vector Machine?
2. SVM giúp giải quyết những bài toán nào trong machine learning?
3. Tại sao ta chuyển bài toán gốc sang hệ KKT/dual thay vì giải trực tiếp primal form?
  - ▶ Support vectors là các samples có constraints đang active.
  - ▶ Chúng quyết định maximum-margin hyperplane.
  - ▶ Dual formulation phụ thuộc vào dot products, từ đó cho phép sử dụng kernels.

## II. Soft-margin Support Vector Machine

### Động lực

Hard-margin SVM yêu cầu dữ liệu linearly separable hoàn toàn. Dữ liệu thực tế thường có noise, overlap và outliers.

- ▶ Soft-margin SVM cho phép kiểm soát các margin violations.
- ▶ Giới thiệu slack variables  $\xi_n$ .
- ▶ Cân bằng giữa margin lớn và classification/margin errors.



### Tài liệu tham khảo

[machinelearningcoban.com/2017/04/13/softmarginsmv/](http://machinelearningcoban.com/2017/04/13/softmarginsmv/)

### Diễn giải slack variable

- ▶ Các điểm trong vùng an toàn:  $\xi_n = 0$ .
- ▶ Các điểm trong vùng không an toàn nhưng vẫn ở đúng phía:  $0 < \xi_n < 1$ .
- ▶ Các điểm nằm sai phía của decision boundary:  $\xi_n > 1$ .

### Ý nghĩa hình học



Slack variables đo mức độ một sample vi phạm yêu cầu margin. Chúng giúp SVM vẫn hiệu quả khi dữ liệu không separable hoàn toàn.

Dựa trên ghi chú Soft-margin SVM của Machine Learning Cơ Bản.

### Bài toán Soft-margin chuẩn

$$(w, b, \xi) = \arg \min_{w, b, \xi} \frac{1}{2} \|w\|_2^2 + C \sum_{n=1}^N \xi_n$$

với các ràng buộc:  $y_n(w^T x_n + b) \geq 1 - \xi_n$  và  $\xi_n \geq 0$ .



### Slater's condition

Với mọi  $n = 1, 2, \dots, N$  và mọi  $(w, b)$ , ta có thể chọn các scalar dương  $\xi_n$  đủ lớn sao cho

$$y_n(w^T x_n + b) + \xi_n > 1, \quad \forall n.$$

### Hệ quả

Bài toán Soft-margin SVM thỏa Slater's condition, do đó strong duality đúng với convex problem này.

### Lagrangian của Soft-margin SVM

$$\begin{aligned}\mathcal{L}(w, b, \xi, \lambda, \mu) = & \frac{1}{2} \|w\|_2^2 + C \sum_{n=1}^N \xi_n \\ & + \sum_{n=1}^N \lambda_n \left( 1 - \xi_n - y_n (w^T x_n + b) \right) - \sum_{n=1}^N \mu_n \xi_n.\end{aligned}$$

- ▶  $\lambda_n \geq 0$  tương ứng với margin constraints.
- ▶  $\mu_n \geq 0$  tương ứng với nonnegative slack constraints.



### Dual function

$$g(\lambda, \mu) = \min_{w, b, \xi} \mathcal{L}(w, b, \xi, \lambda, \mu),$$

với  $\lambda \succeq 0$  và  $\mu \succeq 0$ .

### Dual constraints

Dual problem có thể được viết với

$$0 \leq \lambda_n \leq C, \quad \sum_{n=1}^N \lambda_n y_n = 0, \quad n = 1, 2, \dots, N.$$

### KKT conditions cho Soft-margin SVM

- ▶ Stationarity:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{w}} = 0, \quad \frac{\partial \mathcal{L}}{\partial \mathbf{b}} = 0, \quad \frac{\partial \mathcal{L}}{\partial \xi_n} = 0.$$

- ▶ Primal feasibility: các slack constraints ban đầu được thỏa mãn.
- ▶ Dual feasibility:  $\lambda \succeq 0, \mu \succeq 0$ .
- ▶ Complementary slackness:

$$\lambda_n (1 - \xi_n - y_n (\mathbf{w}^T \mathbf{x}_n + \mathbf{b})) = 0.$$

### Câu hỏi

Có cách nào khác để giải bài toán này không?

### Từ constraints đến dạng hinge

Điều kiện thứ nhất:

$$1 - \xi_n - y_n(w^T x_n + b) \leq 0 \Rightarrow \xi_n \geq 1 - y_n(w^T x_n + b).$$

Điều kiện thứ hai:

$$\xi_n \geq 0.$$

Do đó,

$$\xi_n = \max \left( 0, 1 - y_n(w^T x_n + b) \right).$$

### Unconstrained objective

$$J(w, b) = \frac{1}{2} \|w\|_2^2 + C \sum_{n=1}^N \max \left( 0, 1 - y_n(w^T x_n + b) \right).$$


### Hinge loss cho một sample

$$L(y, f(x)) = \max(0, 1 - yf(x)) .$$

- ▶  $y$ : label thực tế, bằng +1 hoặc -1.
- ▶  $f(x)$ : predicted score trước khi thresholding.
- ▶  $\max(0, \dots)$  bảo đảm loss không âm.

### Diễn giải

Các prediction đúng và có độ tin cậy cao có loss bằng không;  
các prediction không chắc chắn hoặc sai sẽ bị phạt.



### Hinge loss cho Soft-margin SVM

$$L(w, b) = \sum_{n=1}^N \max \left( 0, 1 - y_n (w^T x_n + b) \right) + \frac{\lambda}{2} \|w\|_2^2.$$

### Các phương pháp optimization


- ▶ Gradient Descent
- ▶ Mini-batch Gradient Descent
- ▶ Subgradient methods thường được dùng vì hinge loss không differentiable tại hinge point.

Tài liệu tham khảo: Gradient Descent; Mini-Batch Gradient Descent in Deep Learning.

### III. Kernel Support Vector Machine

#### Ý tưởng chính

Kernel SVM ánh xạ dữ liệu non-linearly separable sang một feature space mới, nơi có thể tồn tại linear separator.



#### Dual problem với dot products

Với dữ liệu gần linearly separable, Soft-margin dual có thể được viết như sau

$$\lambda = \arg \max_{\lambda} \sum_{n=1}^N \lambda_n - \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \lambda_n \lambda_m y_n y_m \mathbf{x}_n^T \mathbf{x}_m$$

với các ràng buộc

$$\sum_{n=1}^N \lambda_n y_n = 0, \quad 0 \leq \lambda_n \leq C.$$

#### Vấn đề

Dữ liệu thực tế thường không gần linearly separable trong không gian gốc.



#### Ánh xạ sang không gian mới

Giả sử ta tìm được hàm  $\Phi(\cdot)$  sao cho mỗi data point trở thành  $\Phi(x)$  và dữ liệu sau biến đổi gần linearly separable.

#### Dual trong không gian biến đổi

$$\lambda = \arg \max_{\lambda} \sum_{n=1}^N \lambda_n - \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \lambda_n \lambda_m y_n y_m \Phi(x_n)^T \Phi(x_m)$$

với các ràng buộc

$$\sum_{n=1}^N \lambda_n y_n = 0, \quad 0 \leq \lambda_n \leq C.$$

#### Định nghĩa kernel

Định nghĩa kernel function

$$K(x_n, x_m) = \Phi(x_n)^T \Phi(x_m).$$

Khi đó dual trở thành

$$\lambda = \arg \max_{\lambda} \sum_{n=1}^N \lambda_n - \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \lambda_n \lambda_m y_n y_m K(x_n, x_m).$$

#### Kernel trick

Ta tính dot products trong feature space mà không cần tính tường minh  $\Phi(x)$ .

#### Prediction dưới dạng kernel

Sử dụng tập support vectors  $S$ , decision score có thể được viết là

$$f(\mathbf{x}) = \sum_{\mathbf{m} \in S} \lambda_{\mathbf{m}} y_{\mathbf{m}} K(\mathbf{x}_{\mathbf{m}}, \mathbf{x}) + b.$$

Predicted class là

$$\text{class}(\mathbf{x}) = \text{sgn}(f(\mathbf{x})).$$

#### Ý tưởng về bias term

Với các margin support vectors,  $b$  được ước lượng từ điều kiện  $y_{\mathbf{n}} f(\mathbf{x}_{\mathbf{n}}) = 1$ .

#### Mercer's condition

Hàm real-valued  $K(x, y)$  thỏa Mercer's condition nếu với mọi hàm square-integrable  $g(x)$ ,

$$\iint g(x)K(x, y)g(y) dx dy \geq 0.$$

#### Dạng tương tự trong trường hợp discrete

Điều này tương tự với một positive semidefinite kernel matrix  $K$ :

$$g^T K g = \sum_{i=1}^N \sum_{j=1}^N g_i K_{ij} g_j \geq 0.$$


Tài liệu tham khảo: Mercer's theorem.

#### Các tính chất


- ▶ Symmetry:  $K(x, z) = K(z, x)$ .
- ▶ Mercer condition: kernel matrix phải positive semidefinite.
- ▶ Giá trị kernel hoạt động như inner products trong một implicit feature space.

#### Các kernel thường dùng


- ▶ Linear:  $K(x, z) = x^T z$
- ▶ Poly:  $K(x, z) = (\gamma x^T z + r)^d$
- ▶ RBF:  $K(x, z) = \exp(-\gamma \|x - z\|^2)$



Linear (underfit)



Polynomial (đường cong) / RBF / Gaussian (các vùng cục bộ)



# IV. Multi-class Support Vector Machine


### Câu hỏi

Làm thế nào để kết hợp SVM và Neural Networks trong một end-to-end architecture?

- ▶ Binary SVM phân tách hai lớp; Multi-class SVM mở rộng ý tưởng margin cho nhiều hơn hai labels.
- ▶ Trong neural classifier, block softmax-cross-entropy cuối có thể được thay bằng SVM-style margin loss.
- ▶ Neural network học feature representations, trong khi SVM head áp đặt score margins giữa lớp đúng và các lớp sai.

### Ý tưởng chính

Sử dụng neural network như một trainable feature extractor và áp dụng Multi-class SVM hinge loss trực tiếp lên các raw class scores cuối.



Không cần xác suất softmax trong quá trình training;  
margin-based loss tác động trực tiếp lên scores.

### Diễn giải architecture

Neural network có thể được train như một feature extractor. Layer cuối xuất raw scores thay vì probabilities, và các scores này được optimize bằng Multi-class SVM margin objective.



### Neural network như một representation learner

Thay vì dùng pipeline cố định như hand-crafted feature extraction → separate classifier, ta xây dựng một deep neural network như CNN.

- ▶ Input data như ảnh hoặc âm thanh được truyền qua các hidden layers.
- ▶ Hidden layers tự động học các task-specific features.
- ▶ Tại layer cuối, ta không áp dụng softmax trong quá trình SVM-style training.
- ▶ Network xuất các raw class scores:

$$z^{(n)} = W h_{\theta}(x^{(n)}) + b, \quad z_j^{(n)} = \text{score của lớp } j.$$

### Bước 2: Áp dụng Multi-class SVM hinge loss

Score vector được truyền trực tiếp vào margin-based loss:

$$L(X, y, W) = \frac{1}{N} \sum_{n=1}^N \sum_{j \neq y_n} \max \left( 0, \Delta - z_{y_n}^{(n)} + z_j^{(n)} \right) + \lambda \|W\|_F^2.$$

Correct-class score  $z_{y_n}^{(n)}$  phải lớn hơn mỗi wrong-class score  $z_j^{(n)}$  ít nhất một margin  $\Delta$ .

### Bước 3: Backpropagation và Gradient Descent

Sau khi tính derivatives của hinge loss, Mini-batch Gradient Descent backpropagate lỗi qua SVM head và neural feature extractor. Quá trình này cập nhật cả SVM weights  $W$  và neural network parameters  $\theta$ .

### Multi-class loss trên toàn dataset

Với toàn bộ dataset  $X = [x_1, x_2, \dots, x_N]$ , total loss là

$$L(X, y, W) = \frac{1}{N} \sum_{n=1}^N \sum_{j \neq y_n} \max \left( 0, \Delta - z_{y_n}^{(n)} + z_j^{(n)} \right).$$

- ▶  $y = [y_1, y_2, \dots, y_N]$  là vector các correct class labels.
- ▶  $z_j^{(n)}$  là score của lớp  $j$  cho sample  $n$ .
- ▶  $1/N$  lấy trung bình loss và giúp tránh giá trị quá lớn.

### Vấn đề

Điều gì xảy ra nếu  $W$  trở nên quá lớn?

### Frobenius norm

Với matrix  $A \in \mathbb{R}^{m \times n}$ , Frobenius norm là

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n a_{ij}^2}.$$


Đây là căn bậc hai của tổng bình phương các phần tử.

### Multi-class SVM loss có regularization

$$L(X, y, W) = \frac{1}{N} \sum_{n=1}^N \sum_{j \neq y_n} \max \left( 0, \Delta - z_{y_n}^{(n)} + z_j^{(n)} \right) + \lambda \|W\|_F^2.$$

### Tính loss function và derivative

- ▶ Tính loss và derivative theo cách naive bằng các vòng lặp.
- ▶ Tính các đại lượng tương tự bằng cách vectorizing các matrix operations.



Broadcasting thay thế các vòng lặp lồng nhau trên samples và classes.

### Naive implementation

Lặp qua samples và classes; dễ hiểu và debug hơn.

### Vectorized implementation

Sử dụng broadcasting, masks và reductions cho datasets lớn.

## Yêu cầu

Áp dụng SVM để classify các image frames trong dataset Tom and Jerry.

Dataset: [Kaggle Tom & Jerry Image Classification](#).

Các target classes



## Kết quả cần nộp

Accuracy, precision, recall, F1-score và confusion matrix trên test set.

## SVM pipeline đề xuất

1. Input: image frame Tom & Jerry



2. Preprocess: loại bỏ viền đen



3. Feature extraction: HOG + RGB histogram



4. Concatenate & normalize features



5. Model: Soft-margin SVM (RBF)



6. Output: One-vs-One voting

- [1] Machine Learning Co Ban. Support Vector Machine.  
[machinelearningcoban.com/2017/04/09/smv/](http://machinelearningcoban.com/2017/04/09/smv/)
- [2] Machine Learning Co Ban. Soft-margin Support Vector Machine.  
[machinelearningcoban.com/2017/04/13/softmarginsmv/](http://machinelearningcoban.com/2017/04/13/softmarginsmv/)
- [3] Machine Learning Co Ban. Kernel Support Vector Machine.  
[machinelearningcoban.com/2017/04/22/kernelsmv/](http://machinelearningcoban.com/2017/04/22/kernelsmv/)
- [4] Adam Rumpf. Introduction to the Karush-Kuhn-Tucker Conditions.
- [5] Tài liệu về Mercer's theorem và kernel methods.

# Thank You

---

## Acknowledgements

[mliotlab.github.io](https://mliotlab.github.io) | 403.1 H6, BKHCM Campus 2  
[mliandiotlab@gmail.com](mailto:mliandiotlab@gmail.com) | [facebook.com/hcmut.ml.iot.lab](https://facebook.com/hcmut.ml.iot.lab) | [youtube.com/@mliotlab](https://youtube.com/@mliotlab)